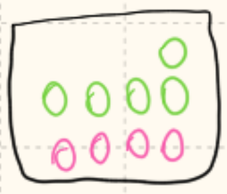
26/08/26

• Repaso probabilidades.



$p(B=V) = \frac{5}{9}$



$p(B=V) = \frac{7}{4}$

r_j		c_j				
	0				x_{04}	
y_7	1	y_{11}	y_{12}	y_{13}	x_{14} y_{14}	y_{15}
	2				x_{24}	
	3				x_{34}	
		1	2	3	4	5

probabilidad conjunta

- $p(X=x_j, Y=y_i) = \frac{n_{ij}}{N}$

probabilidad marginal

- $p(X=x_j) = \sum_{i=0}^{r} \frac{n_{ij}}{N} = \frac{c_j}{N}$
- $p(Y=y_i) = \frac{\sum_{j=0}^{c} n_{ij}}{N} = \frac{r_i}{N}$

- $p(X=x_j) = \frac{\sum_i n_{ij}}{N} = \sum_i p(X=x_i, Y=y_i)$
- $p(Y=y_i) = \sum_j p(X=x_i, Y=y_i)$

- conjunta mi universo es el universo completo, punto especifico entre todo el universo.
- probabilidad condicional

$$p(X=x_4 \mid Y=y_7) = \frac{n_{14}}{\sum_j n_{7j}} = \frac{n_{14}}{r_7}$$ → Todos los datos de la fila (7).

manera matemática $= \frac{n_{ij}}{\sum_j n_{ij}} = \frac{n_{ij}}{r_j}$

$$p(Y=y_i \mid X=x_j) = \frac{n_{ij}}{\sum_i n_{ij}} = \frac{n_{ij}}{c_j}$$

- marginal = Toda una fila o columna dividida entre el total.
- condicional = punto especifico entre toda una fila o columna.

$$p(X=x_j, Y=y_i) = \frac{n_{ij}}{N} = \frac{n_{ij}}{c_j} \cdot \frac{c_j}{N}$$

- conjunta con marginal se hace la prop. de la suma

$$= p(Y=y_i \mid X=x_j)\ p(X=x_j)$$

- $p(Y=y_i, X=x_j) = \frac{n_{ij}}{N} = \frac{n_{ij}}{r_i} \cdot \frac{r_i}{N} = p(X=x_j \mid Y=y_j)\ p(y_i, y_i)$

Propiedad de la suma $p(X=x_j) = \sum_{i=0} p(X=x_j, Y=y_i)$

propiedad del producto $p(X=x_j, Y=y_i) = p(Y=y_i \mid X=x_j)\, p(X=x_j)$

- cantidad de información en terminos de probabilidades.

$$I(x) = -\log_2(p(x)) \Rightarrow \log_2\left(p(x)^{-1}\right) = \log_2\left(1/p(x)\right)$$

* si $p(x)$ es alta, el evento es común, contiene poca información
* si $p(x)$ es baja el evento contiene mucha información.

Teorema de Bayes.

$$p(X=x_j \mid Y=y_i) = \frac{p(Y=y_i \mid X=x_i)\, p(X=x_j)}{p(Y=y_i)}$$

$$p(Y=y_i \mid X=x_j = \frac{p(x=x_j / Y=y_i)\, \underline{p(Y=y_i)}}{\underline{p(x=x_j)}}$$

marginal

marginal

Volviendo con las cajas ★

V = verde
r = roja

B = bola.

$X, Y \in \mathbb{R}$, V.A

$p(B=V) = 5/9 + 2/8 =$

$p(B=r) = \frac{4}{9} + \frac{6}{8}$

$p(C=C_A \mid B=V) =$

$p(C=C_A \mid B=r) = 6/8$

$b(C=C_N \mid B=V) =$

$b(C=C_N \mid B=r) =$

$P(B=V \mid C=C_N) =$

$P(B=r \mid C=C_A) =$ 6/8

$P(B=V \mid C=C_A) =$ 2/8

$P(B=r \mid C=C_N) =$

- $p(C=C_A \mid B=r) = \dfrac{p(B=r \mid C=C_A)\ p(C=C_A)}{p(B=r)}$

37/08/26.

$n_{ij} = p(X=x_j, Y=y_i)$ ①

$\sum_{J=0}^{C} \frac{n_{ij}}{N} = p(Y=y_i)$ ②

$p(Y=y_i) = \sum_{J=0}^{C} p(X=x_j, Y=y_i)$ ③

Condicional

$p(X=x_j \mid Y=y_1) = \dfrac{n_{ij}}{\sum_{J=0}^{C} n_{ij}} = \dfrac{n_{ij}}{r_i}$

- porque algo menos probable me da más información?
- Teorema y Bayes.
- continuas y discretas (probabilidades)
  VARIABLES.
- a, b, c ⇒ vectores A → matriz

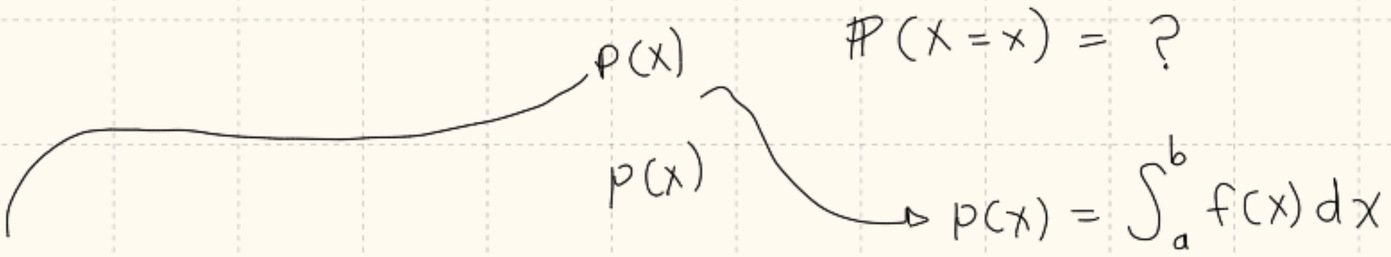
$P(X=x_i) = p(x_i)$ notación discretas. $\mathbb{X} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} \begin{bmatrix} \# \\ \# \\ \# \\ \# \end{bmatrix}$

$P(\mathbb{X} = \mathbb{x}) = p(\mathbb{x})$

como cada variable tiene su propio valor

$P(\mathbb{X} = x_1, \mathbb{X} = x_2, \dots \mathbb{X} = \mathbb{x}_n = p(x_1, x_2 \dots x_n)$

notación continuas



$\int_a^b p(x)dx = P(a \leq x \leq b)$

↳ función de densidad de probabilidades.

$\int_{-\infty}^{+\infty} p(x)dx = 1$

$\sum_{i=0}^{N} P(\mathbb{X} = x_i) = 1$

- Valores de esperanza., distribuciones
- Cual es la probabilidad de un punto especifico en una variable continua? es cero.
- Derivada en python. $\rightarrow \lim_{h \to 0} f'(x) = \frac{f(x) - f(x+1)}{1}$.

$\Rightarrow$ en probabilidad $\lim_{\Delta x \to 0} P(x \leq X \leq x + \Delta x) \approx p(x)$

Repaso: X, Y V.A

2/sep/26
D M A

conjunta : $P(X = x_j, Y = y_i) = \frac{n_{ij}}{N} \cdot \frac{r_i}{N} = P(x = x_j | Y = y_i) P(Y = y_i)$

marginal : $P(X = x_j) = \sum_{i}^{I} P(X = x_j = Y = y_i) = \frac{c_j}{N} = \frac{\sum_{i}^{I} n_{ij}}{N}$

Combinacional: $P(X = x_j \mid Y = y_i) = \dfrac{P(X = x_j, Y = y_i)}{P(Y = y_i)}$

$$P(X = x_j \mid Y = y_i) = \frac{P(Y = y_i \mid X = x_j) P(X = x_j)}{P(Y = y_i)}$$

$P(X)$ = función de masa de probabilidad

$\Rightarrow p(x) = P(X = x_j)$

$p(x, y)$; $P(X|Y)$; $p(x)$, $p(x)$ → Notación

Qué pasa si ahora mi vector con conjunto de variables?

conjunto de valores

$$\mathbb{X} = [X_1, X_2, X_3 \dots X_p]^T$$

$$\mathbb{x} = [x_1, x_2 \dots x_p]$$

$$p(\mathbb{X} = \mathbb{x}) = p(\mathbb{X})$$

continua

$$P(a \leq X \leq b) = \int_a^b p(x)\,dx$$

$p(x)$ = función de densidad de probabilidades.

$$\lim_{h \to 0} \frac{f(x-h) + f(x)}{h} = f'(x) \quad \text{(derivada)}$$

derivada diferencial

$$P(x \leq X \leq x + dx) = \int_x^{x+dx} p(t)\,dt = dP(X = x)$$

$$dP(x) = p(x)\,dx$$

$$p(x) = \frac{d\,\mathbb{P}(x)}{dx}$$

VALOR ESPERADO

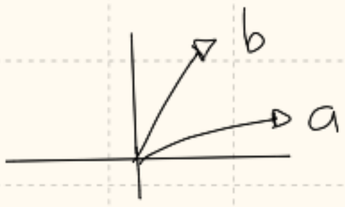
$$E\{X\} = \sum \mathbb{P}(X = x)\, x_n \overset{p(x)}{\longleftarrow} = \frac{1}{N} \sum_{n=0}^{N} x_n$$

$$= \int_{-\infty}^{\infty} x\, p(x)\, dx$$

Distribución uniforme

- condiciones de un espacio de hilbert en L2 (producto interno, norma, distancia métrica)
- muestras i.i.d
- $\langle a, b \rangle = a^T b$

$a b^T$



$$a = \begin{bmatrix} 1 \\ 2 \\ 3 \\ p \end{bmatrix}$$

$a \in \mathbb{R}^{p \times 1}$ vector fila.

$a \in \mathbb{R}^p$

Transpuesta $(1 \times p)(p \times 1) \Rightarrow (p \times 1)(1 \times p)$

1×1 $\quad$ $p \times p$

producto interno

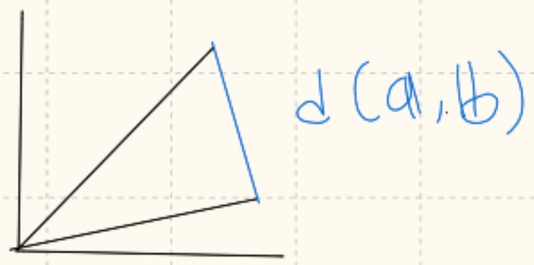
- la norma la definimos con el producto interno.

$$\|a\|_2 = \sqrt{\langle a, a \rangle}$$

$$\|a\|_2^2 = \langle a, a \rangle$$

- Distancia

$$d(a,b) = d(b,a)$$



$\Rightarrow$ condiciones

$$\|a\|_2 = \sqrt{\langle a, a \rangle}$$

$$\|a\|_2^2 = \langle a, a \rangle \in \mathbb{R}$$

$$\varepsilon(a,b) = d^2(a,b) = d^2(b,a) =$$

$$\|a-b\|_2^2 = \langle a-b, a, b\rangle = (a^T - b^T)(a-b)$$

$$\|b-a\|_2^2 = \langle b-a, b-a\rangle = a^T a = a^T b - b^T a + b^T b$$

$$\langle a, a\rangle - \langle a, b\rangle - \langle b, a\rangle + \langle b, b\rangle$$

$$\|a\|_2^2 - 2\langle a, b\rangle$$

$$x^2 + 2xy + y^2$$

- operación matricial con numpy y operaciones elemento a elemento

---

TAREA: $\langle a, b\rangle = \|a\|_2 \|b\|_2 \cos(\theta_{a,b})$ Demostración

producto interno → si el angulo es 90° da como resultado 0

$$\frac{\cos(\theta_{a,b})}{\cos(90° \; \pi/2)} = \frac{\langle a, b\rangle}{\|a\|_2 \|b\|_2} = 0$$ APARTADO GEOMETRICO

0

normas

$$c_n = \frac{\langle x(t), u_n(t)\rangle}{\|u_n(t)\|_2^2}$$

$X, Y \in$ VA

Valor esperado

$$E\{X\} = \sum_{-\infty}^{\infty} x\, p(x)$$

$p(X = x)$

$$p(x) = \frac{dP(X=x)}{dx}$$

$$= \sum_{-0}^{N} \frac{x_i}{N}$$

$$p(x_i) = \frac{x_i}{N} \rightarrow \frac{1}{N}$$

$$= \frac{1}{N} \sum_{l=0}^{N} x_i$$

$X, Y \in \mathbb{R}$

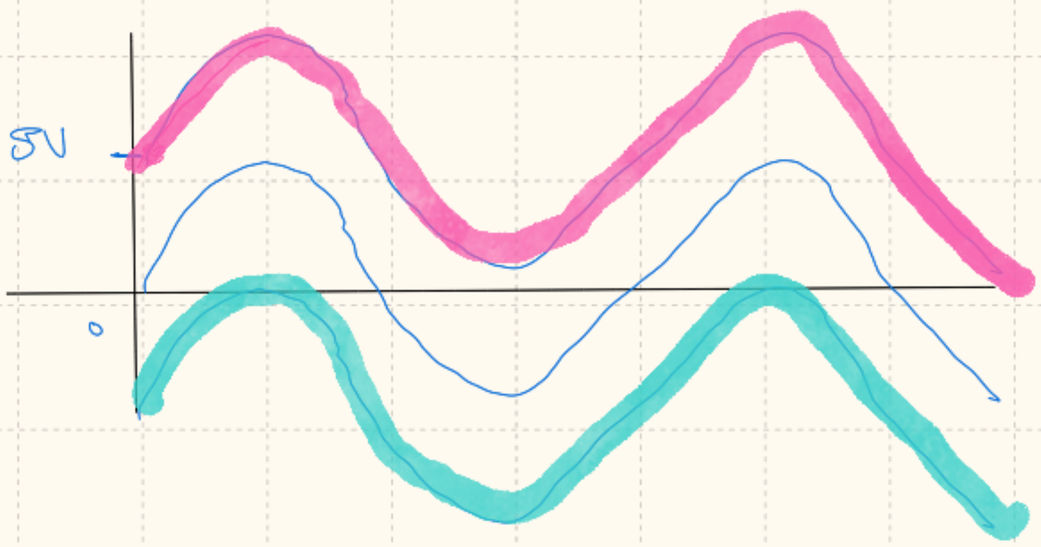
i.i.d

independientes e identicamente distribuidas

$$\Rightarrow E\{X\} = \mu_X \Big\} \in \mathbb{R}$$

momentos esperados:

$$E\{X\} = \mu_X \quad E\{X\} = \mu_Y \Big\} n=1 \qquad E\{X^2\} \quad E\{X^n\} \qquad \Rightarrow \mu_X{}^2 \neq E\{X^2\}$$



la señal es la misma solo esta desfasada

- como es la misma solo se le resta su media

momento centralizado.

$$E\{X - \mu_X\} = E\{X\} - E\{\mu_X\} = \mu_X - \mu_X = \boxed{0}$$

Como los 2 estan centralizados puedo hacer comparaciones directas.

Varianza

$$E\{(X-\mu_X)^2\} = E\{X^2 - 2X\mu_X + \mu_X^2\}$$

$$E\{X^2\} - 2E\{X\mu_X\} + \mu_X^2 = E\{X^2\} - 2\mu_X E\{X\} + \mu_X^2$$

$$= E\{X^2\} - 2\mu_X + \mu_X^2$$

$$= E\{X^2\} - \mu_X \quad *$$

momento cruzado y centralizado.

$E\{X^r Y^s\}$ $\quad n = r+s$

$E\{X\,Y\}$ $\quad n = 2$

- Varianza = 1 Variable
- Covarianza = 2 Variables

$\Rightarrow * \in\{X^2\} - \mu_X \Rightarrow Var(X)$

$\cdot \in\{X^2\} = \in\{XY\}$

$\in\{(X-\mu_X)(Y-\mu_Y)\} = (OV(X,Y)$

$= \in\{XY\} - \in\{X\}\mu_Y - \mu_X \in\{Y\} + \mu_X\mu_Y$

$= \in\{XY\} - \mu_X\mu_Y - \mu_X\mu_Y + \mu_X\mu_Y$

$= \in\{XY\} - \mu_X\mu_Y$

- Indice de correlación de Pirson
- Covarianza

$\Rightarrow P(X,Y) = \frac{COV(X,Y)}{\sqrt{var(x)\,cor(Y)}}$ → $(0,1)$ normalizada.

nunca tiene sentido sacar el indice de correlación de pirson de una misma variable

- $\cos(\theta\, a,b) = \frac{\angle\, a,b >}{\|a\|_2\ \|b\|_2}$

$P(X,Y) = \frac{COV(X,Y)}{\sqrt{Var(X)\cdot Var(X)}}$

$Y, X \in \mathbb{R}^p$

$\in\{X\} = \mu_X \in \mathbb{R}^p$

$\in\{X\} = \begin{bmatrix} \in\{X_1\} \\ \in\{X_2\} \\ \in\{X_3\} \\ \in\{X_\cdot\} \\ \in\{X_p\} \end{bmatrix} = \mu_X = \begin{bmatrix} \mu_{X_1} \\ \mu_{X_2} \\ \vdots \\ \mu_{X_p} \end{bmatrix}$

$\in\{X-\mu_X\} = \emptyset$ Vector de ceros.

$\in\{\{X-\mu_X)\}$

$\in\{(X-\mu_X)^T(X-\mu_X)\}$

$n=2$?

$\chi_1\ \chi_n$

$E\{\langle X-\mu_X, X-\mu_X\rangle\}$ Panorama Global.

Cuando tengo 2 vectores y lo multiplico transpuesto el primero me da una variable aleatoria. Panorama Global.

pero si es transpuesto el segundo tendre una matriz aleatoria.

Panorama Variado.

$$\begin{bmatrix} X_1X_1 & X_1X_2 & X_1X_3 \\ & X_2X_2 & X_2X_3 \\ & & X_nX_n \end{bmatrix}$$

exersise.

- $E\{\langle X-\mu_X, Y-\mu_Y\rangle\} = \frac{1}{N}\sum_{n=0}^{N}\langle X_n-\mu_{X_n}, Y-\mu_{X_n}\rangle$

A i.i.d

$$P(X,Y) = \frac{1}{N}\sum\langle X_n-\mu_n, Y_n-\mu_n\rangle$$

- $E\{\langle X-\mu_X, Y-\mu_Y\rangle\} = \frac{1}{N}\sum_{n=0}^{N}\langle X_n-\mu_{X_n}, X_n-\mu_{X_n}\rangle$

$$\|X_n-\mu_{X_n}\|_2^2$$

se normaliza.

$$p(X,Y) = \frac{\frac{1}{N}\sum\langle X_n-\mu_n, Y_n-\mu_n\rangle}{\sqrt{\|X-\mu_X\|_2^2\,\|Y-\mu_Y\|_2^2}}$$

$$\frac{\frac{1}{N}\sum\langle X_n-\mu_n, Y_n-\mu_n\rangle}{\frac{1}{N}\sum_{n=1}^{N}\|X-\mu_X\|_2\sum_{n=1}^{N}\|Y-\mu_Y\|_2}$$

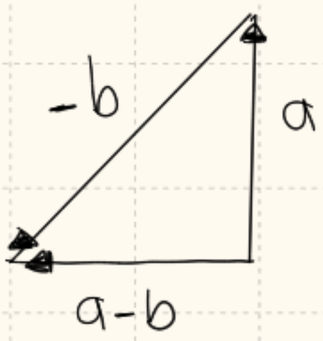
Tarea: como con vectores 1 a la derecha o a la izquierda con o sin transpuesta no debemos reemplazar.

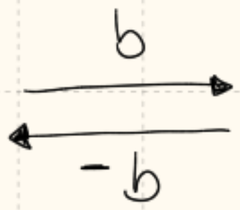
- como sustituir una sumatoria en terminos de vectores de 1, transpuesto o sin transponer a la derecha o la izquierda.

Solución

TAREA: $\langle a, b \rangle = \|a\|_2 \|b\|_2 \cos(\theta_{a,b})$ Demostración

- $\langle a, b \rangle$ → producto interno, o producto escalar
- $\|a\|_2 \|b\|_2$ → norma euclidiana de los vectores, representa fisicamente la longitud o tamaño exacto de la flecha de cada vector
- $\theta_{a,b}$ → ángulo más pequeño que se forma entre los vectores a, b cuando ambos parten del mismo punto de origen
- a-b → vector diferencia





$a - b = a + (-b)$

① ley de cosenos, triangulo vectorial.

$\Rightarrow \|a-b\|_2^2 = \|a\|_2^2 + \|b\|_2^2 - 2\|a\|_2 \|b\|_2 \cos(\theta_{a,b})$

② Desarrollar la norma cuadrada algebraicamente.

por definicion $\|v\|_2^2 = \langle v, v \rangle$ producto interno del vector
↳ norma al cuadrado de un vector

$\Rightarrow \|a-b\|_2^2 = \langle a-b, a-b \rangle$

propiedad distributiva $= \langle a, a \rangle - \langle a, b \rangle - \langle b, a \rangle + \langle b, b \rangle$

simplifico $\Rightarrow$ $\|a-b\|_2^2 = \|a\|_2^2 - 2\langle a,b\rangle + \|b\|_2^2$

igualo

$\|a\|_2^2 - 2\langle a,b\rangle + \|b\|_2^2 = \|a\|_2^2 + \|b\|_2^2 - 2\|a\|_2\|b\|_2\cos(\theta_{a,b})$

Despejar producto interno.

$\frac{-2\langle a,b\rangle}{-2} = \frac{-2\|a\|_2\|b\|_2\cos(\theta_{a,b})}{-2}$

$\Rightarrow \langle a,b\rangle = \|a\|_2\|b\|_2\cos(\theta_{a,b})$

(2)

- como sustituir una sumatoria en terminos de vectores de 1, transpuesto o sin transponer a la derecha o la izquierda.

- Vectorizar una sumatoria, eliminar el simbolo Σ y reescribir la misma operación matematica utilizando álgebra lineal (vector compuesto por 1)
- si x vector columna
- vector de unas dimención N $\quad 1_N = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} \in \mathbb{R}^{N\times 1}$

su transpuesta $\quad 1^T_N = [1\ 1\ \dots\ 1] \in \mathbb{R}^{1+N}$

- vector columna → $X = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix}$ $\Rightarrow$ $\boxed{\sum_{i=1}^{N} = x_i = 1_N^T X}$

porque $1_N^T X = [1\ 1 \dots 1] \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix}$

$1X_N^T = 1x_1 + 1x_2 + \dots + 1x_N$

$\Rightarrow \boxed{1X_N^T = x_1 + x_2 \dots + x_N}$

sus dimenciones son: $(1 \times N)(N \times 1) = 1 \times 1$.
resultado un escalar.

- si X es vector fila.

$X = [x_1\ x_2 \dots x_N] \in \mathbb{R}^{1 \times N}$

$\Rightarrow \boxed{\sum_{i=1}^{N} = X 1_N}$ porque:

$[x_1\ x_2 \dots x_N] \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} \Rightarrow$ Dimencion $(1 \times N)(N \times 1) = 1 \times 1$

$= \boxed{x_1 + x_2 + \dots + x_N}$

Caso de una matriz sumar filas o columnas

$$A = \begin{vmatrix} a_{11} & a_{12} & \cdots & a_{1N} \\ a_{21} & a_{22} & \cdots & a_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ a_{M1} & a_{M2} & \ddots & a_{MN} \end{vmatrix} \qquad A \in \mathbb{R}^{M \times N}$$

$$\Rightarrow \sum_{i=1}^{M} \sum_{j=1}^{N} = 1_M^T A 1_N \quad \cdot \text{ Dimensiones } (1 \times M)(M \times N)(N \times 1)$$

$$\Rightarrow (1 \times M)(M \times N)(N \times 1) = 1 \times 1$$

- $(A 1_n)_i = \sum_{j=1}^{N} A_{ij}$
- sumatoria a lo largo de las filas.

$$(1_m^T A)_i = \sum_{i=1}^{M} (1_M^T) A_{ij} = \sum_{i=1}^{m} (1) A_{ij} = \sum_{i=1}^{m} A_{ij}$$

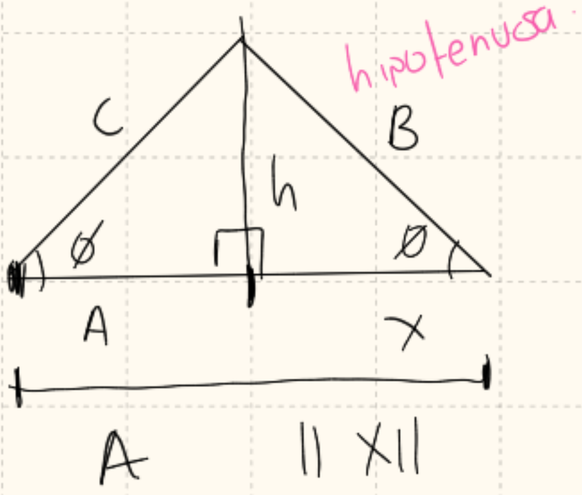
- para todos los elementos de la matriz

$$1_m^T A 1_n = 1_m^T (A 1_N)$$

Sea $Y = A 1_n$ vector columna donde

$$y_1 = \sum_{j=1}^{n} A_{ij} \Rightarrow 1_m^T y = \sum_{i=1}^{m} y_i = \sum_{i=1}^{m} \sum_{j=1}^{n} A_{ij}$$

- Demostración Tarea



(1) Definir Variables

$A, B, C, x, h \in \mathbb{R}^2$

$\cos\phi = \frac{\|x\|}{\|B\|} \Rightarrow \|B\|\cos\phi$

Pitagoras (1)

$\|B\|^2 = \|x\|^2 + \|h\|^2$ (1)

$\|C\|^2 = (\|A\|^2 - \|x\|^2) + \|h\|^2$ (2)

$\|C\|^2 = \|h\|^2 + \|A\|^2 - 2\|A\|\|x\|$

$\|C\|^2 = \|B\|^2 + \|A\|^2 + \|A\|\|B\|\cos\phi$

$\Rightarrow \langle A-B, A-B \rangle = \|A\|_2^2 - 2 <$

Python

- Transpuesta ≠ Reshape (4,3)

(4,3)

- como convierto un tensor en una matriz
- Quiero pasar de tener 3 axis a 2 axis

- $X \in \mathbb{R}^d$

$x_1, x_2 \ldots x_N \in \mathbb{R}^d$

$\in \{X\} = \mu \in \mathbb{R}^d$ en X

- indice de correlación



Tarea: porque la correlación de poison no dio ensendio totulmente toda la diagonal.

Traer código.

¡Es una excelente observación! Que te hayas fijado en ese detalle visual de la gráfica demuestra que estás analizando los resultados con mucha atención, más allá de solo ejecutar el código.

Tienes toda la razón: la diagonal de la matriz de correlación de Pearson se ve como una línea punteada o entrecortada. Esto ocurre por la combinación de una anomalía matemática en los datos y un efecto visual.

1. La Matemática de los "Píxeles Muertos"

- **La teoría perfecta:** Como tienes anotado en tus apuntes, la correlación de una variable consigo misma siempre debe dar la unidad: $\rho(X,X) = \frac{\mathrm{Cov}(X,X)}{\sqrt{\mathrm{Var}(X)}\sqrt{\mathrm{Var}(X)}} = 1.$ PDF
- **La realidad de MNIST:** Las imágenes de los números manuscritos están centradas en un lienzo de **28x28** píxeles. Los píxeles de los bordes y las esquinas siempre son completamente negros en todas las muestras.
- **Varianza nula:** Como esos píxeles jamás cambian de valor, su varianza matemática es exactamente cero ($\mathrm{Var}(X) = 0$).

2. La Indeterminación en el Código

- **El problema del 0/0:** Al intentar calcular la correlación de un píxel negro consigo mismo, la fórmula intenta dividir la covarianza (que es cero) entre la varianza (que también es cero). PDF
- **La trampa en programación:** Para evitar que el programa colapse por una división por cero, el código reemplaza artificialmente esa desviación estándar por **1**.
- **El resultado:** Esto provoca que la correlación de ese píxel "muerto" consigo mismo termine evaluándose como **0** en lugar de **1**.

- Para solucionar el problema del cero se usa un epsilon

$\varepsilon = 7e^{-6}$

$\rho(x_{p7}, x_{p7}) = \frac{0}{0} \overset{\infty}{\rightarrow} \varepsilon$

- En nivel de pixeles es más común tener lo siguiente

$(x_i - \mu)^T (x_i - \mu)^T$ (0 y 0)

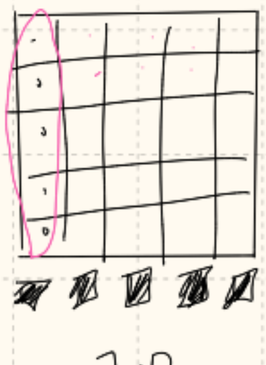
- $\mathbb{X} \in \mathbb{R}^{N \times p}$

$$\bar{X}_p = \frac{1}{N} \sum_{n=a}^{N} \chi_{n,p}$$

$$\bar{X}_N = \frac{1}{p} \sum_{p=0}^{p} \chi_{n,p}$$

Important.

Demostración.



$1/p$

$$1^T \mathbb{X} = \bar{\mathbb{X}}_p \in \mathbb{R}^{1 \times p}$$

$$[1_0, 1_1, 1_2, \dots 1_N] = \begin{vmatrix} \chi_{11} & \chi_{12} & \chi_{1P} \\ \chi_{21} & \chi_{22} & \chi_{2P} \\ \vdots & \vdots & \vdots \\ \chi_{N1} & \chi_{N2} & \chi_{NP} \end{vmatrix} = \chi_{11} + \chi_{21} + \dots + \chi_{N1}$$

$$\Rightarrow \bar{X}_p = \frac{1}{N} \sum_{n=1}^{N} \chi_{n,p} = \frac{1}{N} \cdot 1_N^T \mathbb{X}$$

$$\Rightarrow \bar{X}_N = \frac{1}{p} \sum_{p=0}^{p} X_{n,p} = \frac{1}{p} \mathbb{X}^{N \times p} 1_p$$

→ vector de 1_s.

En computación → Operación matricial

Demostración de covarianzas con los mismos indices hacer su equivalente matricial.

- $\mathbb{X} \in \mathbb{R}^{N \times p}$, $\mathbb{Y} \in \mathbb{R}^{N \times p}$

conjunto de vectores: $\{\mathbb{X}_p\}_{n=1}^{N}$

$\{\mathbb{X}_N\}_{p=1}^{P}$

Si $\{\mathbb{X}_p \in \mathbb{R}\}^p$ que dimensiones tiene?

$\Rightarrow \{X_{np} \in \mathbb{R}\}_{p=1}^{p}$; $n \in N$ $\}$

y para el otro conjunto:

$\{X_{np} \in \mathbb{R}^N, p \in P\}$.

$\} X \in \mathbb{R}^{N \times p}$

$X_{C2}, X_{C1} \in \mathbb{R}^{N \times 1}$

$X_{C1}^T X_{C2} =$ número

asumiendo iid

X_{C1} X_{C2}

$$cov(X_{n1}, X_{n2}) = E\{\langle X_{n1} - \hat{\mu}_p, X_{n2} - \hat{\mu}_p \rangle\} = \frac{1}{N} \sum_{n=0}^{N} \langle X_{n1} - \mu_1, X_{n2} - \mu_2 = \frac{1}{N} X_C^T X_C \quad (*)$$

$$cov(X_{1p}, X_{2p}) = E\{\langle X_{1p} - \hat{\mu}_n, X_{p2} - \hat{\mu}_n \rangle\} \overset{iid}{=} \frac{1}{p} \sum_{P=0}^{p} \langle X_{1p} - \tilde{\mu}_1, X_{2p} - \hat{\mu}_2 \rangle = \frac{1}{p} X_n^T X_n \quad (*)$$

- $\mu \in \mathbb{R}^p$

$\mathbb{1}_N \in \mathbb{R}^{N \times 1}$

$X^{N \times p}$ → prom a nivel de pixel. $N \times p$

$$X_C = X - \mathbb{1}_N^T X \in \mathbb{R}^{N \times p}$$

$N \times p$ $N \times 1, 1 \times p$

promedio a nivel de imagen

$$\tilde{X}_C = X - X \mathbb{1}_p \mathbb{1}_p^T$$

$N \times p$ $N \times p$ $N \times 1$ $1 \times p$ $p \times p$ $N \times p$

$\Rightarrow (*) \frac{1}{N} X_C^T X_C =$ $p N$ $N \times p$

- Hay que programarlo.
  la diagonal no tendra ceros
- indice de correlación de person en matricial.

$X \in \mathbb{R}^{N \times p}$

matriz $\begin{vmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & & \vdots \\ x_{N1} & x_{N2} & \cdots & x_{N3} \end{vmatrix}$

vamos a sacar covarianza con respecto a filas y columnas.

Primera fila 1 comparado con fila 2.

$\Rightarrow cov(X_{1p}, X_{2p}) = N \times N$

se hace comparación entre todas las filas hasta $N \times N$.

- Por cada fila se va a sacar un promedio.

$X \in \mathbb{R}^{N \times p}$

matriz $\begin{vmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & & \vdots \\ x_{N1} & x_{N2} & \cdots & x_{N3} \end{vmatrix}$ $\begin{matrix} \rightarrow \mu_1 = (x_{11} + x_{12} + \cdots + x_{1p})/p \\ \rightarrow \mu_2 = (x_{21} + x_{22} + \cdots + x_{2p}/p \\ \vdots \\ \rightarrow \mu_N = N \text{ veces} \end{matrix}$ } ✳

con esto necesitamos construir señales que no tengan valores promedios para eso hacemos lo sg:

$\begin{vmatrix} x_{11}-\mu_1 & x_{22}-\mu_2 & \cdots & x_{2p}-\mu_2 \\ x_{21}-\mu_2 & x_{22}-\mu_2 & \cdots & x_{2p}-\mu_2 \\ \vdots & \vdots & & \vdots \\ x_{N1}-\mu_N & x_{N2}-\mu_N & \cdots & x_{Np}-\mu_N \end{vmatrix}$

→ $X_{f1}, X_{f2} \rightarrow \in \mathbb{R}^p$

$X_{f1}^T, X_{f2} = \#$

$X_{f2}^T, X_{f2} = \#$

$\vdots$

$X_{fN}^T X_{fN} = \#$

} Todas las combinaciones posibles en una tabla

$\begin{bmatrix} \#f_1f_1 & \#f_1f_2 & - & - & - \\ \#f_2f_1 & \ddots & & & \\ \vdots & & \ddots & & \\ & & & \ddots & \end{bmatrix}$ tamaño $N \times N$

Para buscar el vector promedio (μ)

$$\begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_N \end{bmatrix} \in \mathbb{R}^{N\times 1} \longrightarrow \boxed{\frac{1}{p}\ \underset{N\times p}{X}\ \underset{p\times 1}{1}}$$

X multiplicado matricialmente por un vector de unos.

comprobada matematicamente.

porque $* = 0$

- Toda una fila multiplicada por una columna de 1.

$$\frac{1}{p}\cdot\begin{vmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & & \vdots \\ x_{N1} & x_{N2} & \cdots & x_{N3} \end{vmatrix}\begin{vmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{vmatrix} = \begin{matrix} (x_{11}+x_{12}+\cdots x_{1p})/p \\ (x_{21}+x_{22}+\cdots x_{Np})/p \end{matrix} \Rightarrow \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_N \end{bmatrix}$$

$$\Rightarrow \frac{1}{p}\cdot\begin{vmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & & \vdots \\ x_{N1} & x_{N2} & \cdots & x_{N3} \end{vmatrix} - \begin{vmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_N \end{vmatrix}\begin{bmatrix} 1 & 1 & \cdots & 1 \end{bmatrix} \Rightarrow \begin{bmatrix} \mu_1 & \mu_1 & \cdots & \mu_N \\ \mu_2 & \mu_2 & \cdots & \mu_N \end{bmatrix} = \begin{vmatrix} \overline{x_{11}}-\mu_1 & x_{12}-\mu_2 \end{vmatrix}$$

NXP $\qquad$ NXP

$\Rightarrow$ Con esto demostramos que $\underbrace{X - \frac{1}{p}X}_{NXP}\ \underbrace{1_p 1_p}_{PX1}$

$\Rightarrow Cov(x_{N1}, x_{N2})$

- Con solo restar las medias se centran $\Rightarrow \boxed{X_c}$

$$\Rightarrow \frac{X_{f1}^T X_{f2}}{\sqrt{Var(X_{f1})\ Var(X_{f2})}}$$

$\rightarrow Var^2(X_{f1})$ Porque en la misma.

$$X_c^T X_c \in \mathbb{R}^{N\times N} \Rightarrow Cov(X,X) = \begin{bmatrix} Cov(X_{f1},X_{f1}) & Cov(X_{f1},X_{f2}) \cdots & Cov(X_{f1},X_{fN} \\ Cov(X_{f2},X_{f1}) & & \\ & & Var^2(X_{fN}) \end{bmatrix}$$

$$\Rightarrow \begin{vmatrix} 1 & \frac{cov(X_{f1}, X_{f2})}{\sqrt{var(X_1)\, var(X_2)}} \\ \frac{cov(X_{f1}, X_{f2})}{\sqrt{var(X_1)\, var(X_2)}} & 1 \end{vmatrix}$$

$$\Rightarrow \frac{X_{f1}^T X_{f2}}{\sqrt{var(X_{f1})\, Var(X_{f2})}} \Rightarrow f_2 = f_1 \cdot \frac{var(X_{f1})}{var(X_{f1})\, Var(X_{f1})} = 1$$

$\frac{\varepsilon}{\varepsilon} = 1$

No existe la division matricial.

① vector

$$\sqrt{trace(cov)} = \begin{vmatrix} \sqrt{var(X_{f1})} \\ \sqrt{var(X_{f2})} \\ \vdots \\ \sqrt{var(X_{fN})} \end{vmatrix} \in \mathbb{R}^{N \times 1}$$

$$\sqrt{\begin{bmatrix} var(X_1) \\ \vdots \\ var(X_{fN}) \end{bmatrix}} \begin{bmatrix} \sqrt{var(X_{f1})} & \sqrt{var(X_{f2})} \end{bmatrix}$$

Para programar se resume en:

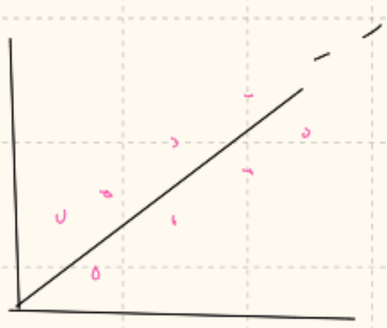
$$\frac{cov(\cdot)}{\sqrt{trace(cov)}\ \sqrt{trace^T(cov)}}$$

14/09/26

Generar un grafico modelo de datos

$y = mx + b \rightarrow$ linea recta

$y = f(x) + \eta \rightarrow$ nivel de ruido

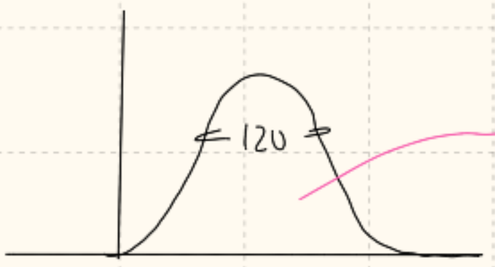


Si se quiere generar un modelo con IA

$$\eta \longrightarrow \text{IA}$$

y ahora como podemos encontrar ese modelo $f(x)$

→ si $\eta \sim N(\mu | \theta^2)$ → distribucion normal - Gausiana (que sigue el ruido)



$$p(x) \longrightarrow \int_{-\infty}^{\infty} p(x)\,dx = 1$$

$$\int_{-\infty}^{\infty} N(x, \mu/\sigma^2)\,dx = 1$$

$$\Rightarrow E\{x\} = \int_{-\infty}^{\infty} x\,p(x)\,dx = \mu \quad \text{Demostrar.}$$

$$x \sim N(x, \mu/\sigma^2) =$$

- Resolver

$$\Rightarrow \int_{-\infty}^{\infty} x \cdot \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(\frac{-\|x-\mu\|_2^2}{2\sigma^2}\right) dx$$

Cambio de variable. $z = \dfrac{x-\mu}{\sigma^2} = 2.\sigma + \mu = x$

$$dz = \frac{dx}{\sigma} \Longrightarrow dx = \sigma\,dz$$

$$\frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{\infty} (z\sigma + \mu) \exp\left(\frac{-z^2}{2}\right) \emptyset\, dz$$

$$\frac{1}{\sqrt{2\pi}} \left[\int_{-\infty}^{\infty} z \exp\left(-\frac{z^2}{2}\right) dz \; \frac{+\mu}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \exp\left(\frac{z^2}{2}\right) dz \right.$$

$$\left. + \mu \left(\int_{-\infty}^{\infty} N(z, 0|1)\,dz \right) \right] \quad \rightarrow 1$$

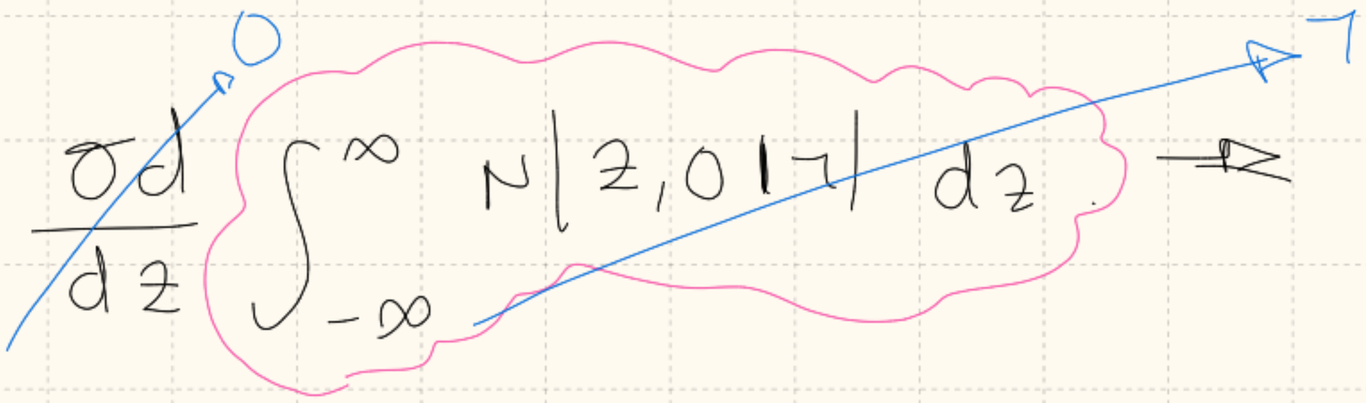
$$\Rightarrow \frac{70}{\sqrt{2\pi}} \int_{-\infty}^{\infty} z \cdot \exp\left(\frac{-z^2}{2}\right) dz + u$$

$$\left\{ \Rightarrow z \exp\left(\frac{-z}{2}\right) \quad \cancel{du} \quad \frac{d \exp\left(\frac{-z^2}{2}\right)}{dz} \right.$$

$$\left. = \exp\left(-\frac{z^2}{2}\right) \cdot -\frac{2z}{4} = -2z \right\}$$

$$\Rightarrow \frac{\sigma}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \frac{d \exp\left(\frac{-z^2}{2}\right)}{dz} dz$$

$$\rightarrow \frac{\sigma d}{dz} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}^1} \exp\left(\frac{-z^2}{2}\right) dz$$



- Demostrar que: $E\{X^2\} = \int_{-\infty}^{\infty} x^2 p(x)\, dx = ?$

si $p(x) = N(x, u|\sigma^2)$

$$\int_{-\infty}^{\infty} x^2 \cdot \frac{1}{\sqrt{2\pi\sigma^2}^1} \exp\left(\frac{-||x-u||^2}{2\sigma^2}\right) dx$$

cambio de variable $\rightarrow z = \frac{x-u}{\sigma} \Rightarrow \sigma z + u = x$

$$(\sigma z + u)^2 = x^2$$

$$dz = \frac{dx}{\sigma}$$

$$\sigma\, dz = dx$$

- $E\{X\} = \frac{1}{N}\sum_{n=1}^{N} x_n = \mu_n$

$E\{X\} = \mu$

$E\{X^2\} = \mu^2 + \sigma^2$

$$\Rightarrow \int_{-\infty}^{\infty} (\sigma z + \mu)^2 \exp\left(\frac{-z^2}{2}\right) \sigma\, dz$$

$$\Rightarrow \int_{-\infty}^{\infty} (\sigma^2 z^2 + 2\sigma z + \mu^2) \exp\left(\frac{-z^2}{2}\right) \cdot dz$$

$$\Rightarrow \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \sigma^2 z^2 \exp\left(\frac{-z^2}{2}\right) dz + \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} 2\sigma z \exp\left(\frac{-z^2}{2}\right) dz +$$

$$\frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \mu^2 \exp\left(\frac{-z^2}{2}\right) dz$$

$$\Rightarrow \frac{\sigma^2}{\sqrt{2\pi}} \int_{-\infty}^{\infty} z^2 \exp\left(\frac{-z^2}{2}\right) dz + \frac{2\sigma}{\sqrt{2\pi}} \int_{-\infty}^{\infty} z \exp\left(-\frac{z^2}{2}\right) dz + \frac{\mu^2}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \exp\left(\frac{-z^2}{2}\right) d$$

0 $\qquad$ 1

$+ \quad 0 \quad + \quad \mu^2$

Cambio

$$\Rightarrow z\left(z \exp\left(-\frac{z}{2}\right) = z\, d\exp\left(-\frac{z^2}{2}\right)\right.$$

$$\frac{}{dz}$$

$$\Rightarrow \frac{-\sigma^2}{\sqrt{2\pi}} \int_{-\infty}^{\infty} z\, d\exp\left(\frac{-z^2}{2}\right) dz \longrightarrow \text{cambio de variable}$$

$u = z$ $\qquad$ $dv = d\exp\left(\frac{-z^2}{2}\right) dz$

$dv = dz$

$v = \exp\left(\frac{-z^2}{2}\right)$

$$\Rightarrow \frac{1}{2\pi} \cdot z \exp\left(\frac{-z^2}{2}\right)\Big|_{-\infty}^{\infty} = \frac{1}{e^{-\infty}} = \frac{1}{\infty} = 0$$

$$\Rightarrow \quad 0 \quad -\frac{1}{2\pi}\int_{-\infty}^{\infty} d\exp\left(\frac{-z^2}{2}\right) dz \qquad 1$$

$$\sigma^2$$

solución final

$$\Rightarrow \boxed{\sigma^2 + \mu^2}$$

- $E\{X\} = \frac{1}{N}\sum_{n=1}^{N} x_n = \mu_n$

$$E\{X\} = \mu$$

$$E\{X^2\} = \mu^2 + \sigma^2$$

$$E\{(x-\mu)^2\} = \sigma^2$$

$$Var\{X\} = \sigma^2$$

$$\Rightarrow E\{x-\mu)^2\} = E\{x^2 - 2\mu x + \mu^2\}$$

$$= E\{X^2\} - 2\mu E\{X\} + (E\{X\}^2)$$

$$= \mu^2 + \sigma^2 - 2(E\{X\})^2 + (E\{X\})^2$$

$$= \mu^2 + \sigma^2 - (E\{X\})^2$$

$$= \mu^2 + \sigma^2 - \mu^2$$

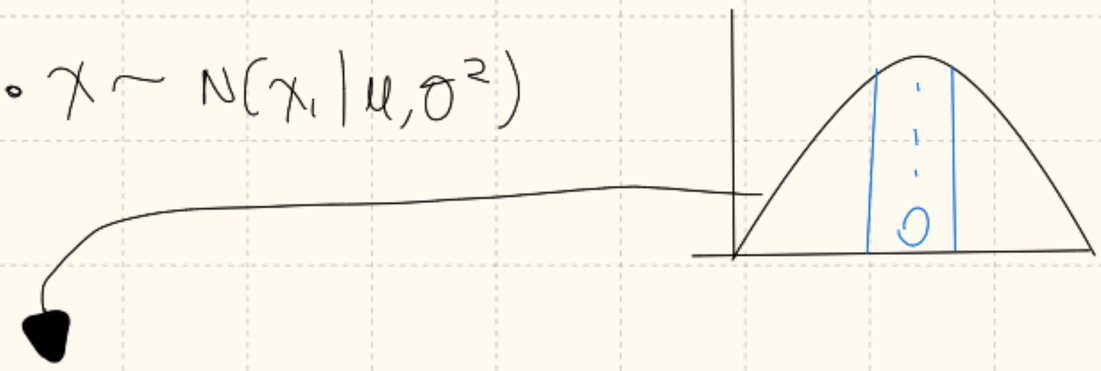
$$= \sigma^2$$

16/09/26

$$E(\chi) = \mu \Rightarrow iid = \frac{1}{N}\sum_{n=1}^{N} \chi_n$$

$$\mu \Rightarrow p(\chi) = N(\chi \mid \mu, \sigma^2)$$

- $\chi \sim N(\chi_1 \mid \mu, \sigma^2)$



$$\mathbb{X} = [\chi_1, \chi_2, \chi_3, \dots \chi_N]$$

- $p(\mathbb{X}) = p(\chi_1, \chi_2 \dots \chi_N)$

iid

$$p(\mathbb{X}) = p(\chi_1)\, p(\chi_2)\, p(\chi_3) \dots p(\chi_N).$$

$$= N(\chi_1 \mid \mu, \sigma^2)\, N(\chi_2 \mid \mu, \sigma^2) \dots N(\chi_N \mid \mu, \sigma^2)$$ → misma media, misma varianza.

$$\Rightarrow p(\mathbb{X}) = \prod_{n=1}^{N} N(\chi_N \mid \mu, \sigma^2)$$ → productoria.

maximizar $\Rightarrow \max_{\mu, \sigma^2} p(\mathbb{X}) = \max_{\mu, \sigma^2} \prod_{n=1}^{N} N(\chi_n \mid \mu, \sigma^2)$

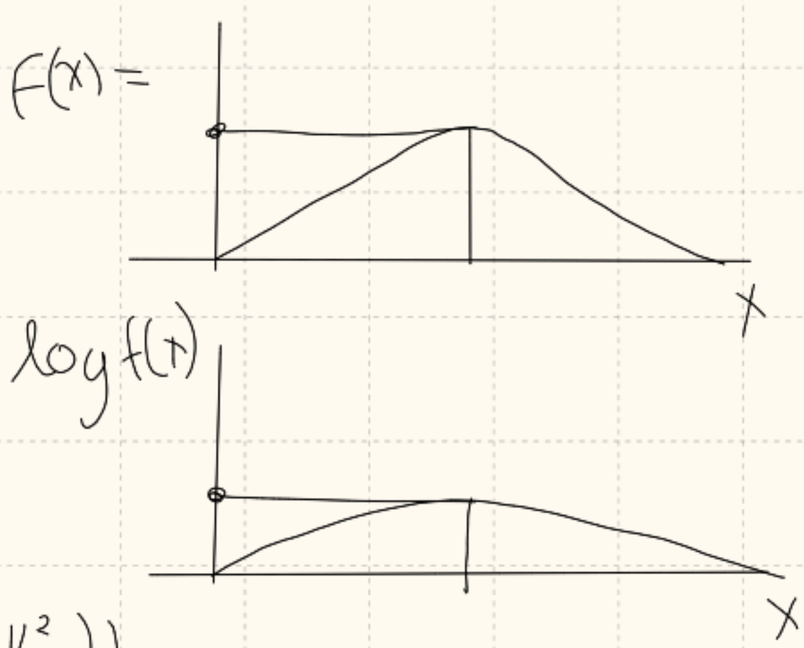
para encontrar μ = constante.
" " σ = constante.

$$\Rightarrow \max_{\mu} \prod_{n=1}^{N} N(\chi_n \mid \mu, \sigma^2)$$

$$\max_{\mu} \log\left(\prod_{n=1}^{N} N(\chi_n \mid \mu, \sigma^2)\right)$$

$$\max_{\mu} \sum_{n=1}^{N} \log(N(\chi_n \mid \mu, \sigma^2))$$

$$\max_{\mu} \sum_{n=1}^{N} \log\left(\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{\|\chi_n - \mu\|_2^2}{2\sigma^2}\right)\right)$$



Prop log.

$$\log(ab) = \log(a) \cdot \log(b)$$

$$\log\left(\frac{a}{b}\right) = \log(a) - \log(b)$$

$$\log(a^b) = b \log(a)$$

$$= \max_{\mu} \sum_{n=1}^{N} -\frac{\log(2\pi\sigma^2)}{2} - \frac{\|x_n-\mu\|_2^2}{2\sigma^2}$$

$$= \mu^* = \frac{d}{d\mu} \sum_{n=1}^{N} -\frac{1}{2}\log(2\pi\sigma^2) - \frac{(x_n-\mu)^2}{2\sigma^2} = 0 \quad (*)$$

$$= \sum_{n=1}^{N} \frac{d(x_n-\mu)^2}{du\,2\sigma^2}$$

$$= \sum_{n=1}^{N} x_n - \mu_N$$

$$\mu = \frac{1}{N}\sum_{n=1}^{N} x_n$$ → promedio de las valores que tengo.

$$\sigma^2 = E\{(x-\mu)^2\}$$

para vectores de variables

$$\sigma^2 = \frac{1}{N}\sum_{n=1}^{N}(x_n-\mu)^2$$ ¿como llegamos a esto si $\max_{\sigma} \prod_{n=1}^{N} N(x_n|\mu,\sigma^2)$

- partimos desde $(*)$

$$\mu^* = \frac{d}{d\mu} \sum_{n=1}^{N} -\frac{1}{2}\log(2\pi\sigma^2) - \frac{(x_n-\mu^2)}{2\sigma^2} = 0$$

$$\Rightarrow \max_{\sigma^2} \sum_{n=1}^{N} -\frac{1}{2}\log(2\pi) - \frac{1}{2}\log(\sigma^2) - \frac{\|x_n-\mu\|^2}{2\sigma^2}$$ → factoriza

$$\frac{d}{dS} \sum_{n=1}^{N} \log(2\pi) + \log(s) + \frac{\|x_n-\mu\|^2}{S} = 0$$ (0) $\sigma^2 = S$

$$\sum_{n=1}^{N} \frac{1}{S} - \frac{1}{S^2}\|x_n-\mu\|^2 = 0$$

$$\frac{N}{S} - \frac{1}{S^2}\sum_{n=1}^{N}\|x_n-\mu\|_2^2 = 0$$

$$S^2 + \frac{1}{S^2}\sum_{n=1}^{N}\|x_n-\mu\|_2^2 = \frac{N}{S}S^2$$

$$\frac{1}{N}\sum_{n=1}^{N}\|x_n-\mu\|_2^2=\sigma^2$$

$$y=f(x)+\varepsilon \quad \text{— Ruido}$$

$$y=xw+\varepsilon$$

Yo quiero predicir $\hat{y}$

$$\rightarrow(\hat{y}-xw)=\varepsilon$$

$$(x\hat{w}-xw)=\varepsilon$$

Para buscar que un error sea pequeño se minimiza

$$\min_w \|y-xw\|_2^2$$

$$y\in\mathbb{R}^N$$
$$x\in\mathbb{R}^{N\times p}$$
$$N\in\mathbb{R}^{p\times 1}$$

$$\frac{d}{w}\langle y-xw,\ y-xw\rangle=0$$

$$\frac{d}{w}(y-xw)^T(y-xw)=$$

¿Que dimensiones tiene? → $1\times N \quad N\times p = p\times 1$ (1×1)

1×1

$$\frac{d}{w}\left(y^Ty-y^Txw-w^Tx^Ty+w^Tx^Txw\right)=0$$

$$-2y^Txw+2x^Txw=0$$

$p\times N \quad N\times p$ ($p\times p$)

$$-2y^Txw=-2x^Txw$$

$$(x^Tx)^{-1}y^Tx=(x^Tx)^{-1}x^Txw$$

$$\boxed{(x^Tx)^{-1}y^Tx=w}$$

$$0 = ||Xw - X\hat{w}||$$

$$Y = Xw + \varepsilon$$

$$||Xw + \varepsilon - X\hat{w}||_2^2 \neq 0$$

- minimos cuadrados si le metemos ruidos se rompen hay que regular.

$$\min_w ||Y - Xw||_2^2 - \lambda ||w||_2^2$$

$$\frac{d}{dw} Y^TY - 2Y^TXw + w^TX^TXw - \lambda w^Tw = 0$$

$$-2Y^TX + 2X^TX\hat{w} - 2\lambda\hat{w} = 0$$

$$-Y^TX + (X^TX - I\lambda)w = 0 \longrightarrow \text{se invierte todo}$$

$$w = (X^TX - I\lambda)^{-1}Y^TX = w$$

mínimos cuadrados regularizados

$$MC = = MCR(\lambda = 0)$$

- consultar teorema de Bayes
  máxima verisimilitud
  máximo posteriori
  Kernels

- Teorema de Bayes: $P(\theta|X) = \frac{P(X|\theta)P(\theta)}{P(X)}$

nos permite calcular la proba de una hipotesis θ dado que hemos observado ciertos datos (X)

$P(X|\theta)$: que tan probables son los dato si asumimos que θ es cierta.

$P(\theta)$: A priori: lo que creíamos sobre θ antes de ver los datos.

$P(X)$: la probabilidad total de observar esos datos bajo todas las hipotesis (θ) posible

máxima verosimilitud

conjunto de datos medidas sin conocer los parametros del sistema que los generó (media y varianza)

- MLE dice Busca los parametros (θ) que hagan que los datos sean lo más probable posible.

$$\theta_{MLE} = \arg\max_{\theta} \log P(X|\theta)$$

Resumen 17/09/26

Resumen:

$\mathbb{X} = [X_1, X_2 \dots, X_N]$ $\quad X_n \sim \mathcal{N}(X_n|\mu,\sigma^2)$

$P(\mathbb{X}) \Rightarrow$ i.i.d $\Rightarrow$ $P(\mathbb{X}) = P(X_1)P(X_2)\dots P(X_n)$

$\mathcal{N}(X_1|\mu,\sigma^2)\dots\mathcal{N}(X_n|\mu,\sigma^2)$

$$\underset{\mu,\sigma^2}{\arg\max} \log\left(\prod_{n=1}^{N} \mathcal{N}(X_n|\mu,\sigma^2)\right)$$

$$\mu_{MLE} = \frac{1}{N}\sum_{n=1}^{N} X_n$$

$$\sigma^2_{MLE} = \frac{1}{N}\sum_{n=1}^{N} (X_n - \mu_1)^2 \quad \text{media muestral}$$

$Y = XW + \varepsilon$ ← user

asumimos que ε se va con $\hat{Y}$

$\hat{Y} = \mathbb{X}\hat{W}$

user

$$\min_{\hat{W}} \|Y - \hat{Y}\|_2^2 - \lambda\|\hat{W}\|_2^2$$

$^{-1}$ ⇒ Inversa.

$$\frac{d}{d\hat{w}} \|Y - X\hat{w}\|_2^2 - \lambda \|\hat{w}\|_2^2 = 0$$

$$\hat{w} = (X^T X - \lambda I)^{-1} Y^T X$$

mínimos cuadrados regularizado

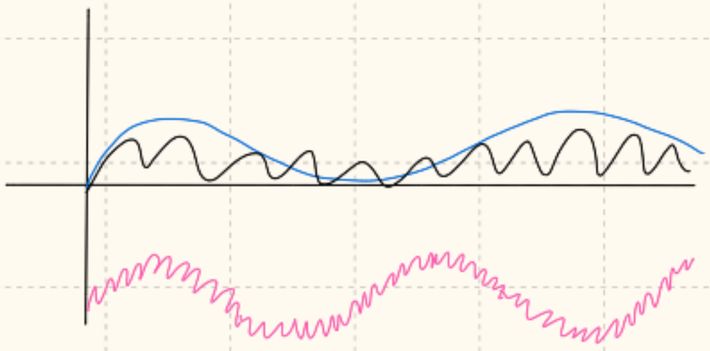
la única variable desconocida en este caso es w.

⇒ Y = ? ∘ ?

$$y = Xw + \varepsilon$$

Caso 1 : $\varepsilon \sim N(0, \sigma^2)$

Caso 2 : $w \sim N(0, \sigma^2)$



Caso 1 ⇒ $Y = (F(X) + \varepsilon) \sim \mathbf{N}(Y \mid f(X), \sigma^2)$ ✳

$\mathbf{N}(Y \mid Xw, \sigma^2)$ ✳

Resolviendo ✳

$$p(Y) = p(Y_1) \cdot p(Y_2) \dots p(Y_n)$$

$$= N(Y_1 \mid X_1 w, \sigma^2) \dots p(Y_n \mid X_n w, \sigma^2)$$

$$p(Y) = \prod_{n=1}^{N} N(Y_n \mid X_n w, \sigma^2)$$

(Y_n: user; X_n w: user)

$$\max_w \; p(Y)$$

$$\max_w \; \log(p(Y))$$

$$\max_w \; \log\left(\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(\frac{-\|Y_n - X_n w\|_2^2}{2\sigma^2}\right)\right)$$

(X_n w: media)

$$\max_w \; \sum_{n=1}^{N} \left(-\frac{1}{2} \log 2\pi\sigma^2\right) = \frac{\|Y_n - X_n w\|_2^2}{2\sigma^2}$$

$$\rightarrow \max_{w} -\sum_{n=7}^{N} ||y_n - x_n w||_2^2 = \min_{w} \boxed{\sum_{n=1}^{N} ||y_n - x_n w||_2^2}$$

$$\downarrow$$

$$\min_{X} ||y - Xw||_2^2 \quad \text{llegamos a} \heartsuit$$

sk learn y linear regresion. → Buscar en internet.

$$\min_{w} ||Xw - y||_2^2$$

caso 2: $w \sim N(w_n | 0, \sigma^2)$

como me paso a Bayes, porque?

Vamos a buscar el w que mas probable sea a los datos

$$p(w|y) = p(y|f(x), \sigma^2)\, p(w_n|0, \sigma^2)$$

$$\max_{w} \log(p(w|y)) = \max_{w} \log\left(\prod_{n=1}^{N} N(y_n|x_n w, \sigma^2)\, N(w_n|0, \sigma^2)\right)$$

$$\Rightarrow \max_{w} \sum_{n=1}^{N} \log(N(y_n|x_n w, \sigma_1^2) + \log(N(w_n|0, \sigma_2^2)$$

$$\max_{w} \sum_{n=1}^{N} \log\left(\frac{1}{\sqrt{2\pi\sigma_1^2}} \exp\left(\frac{-||y - x_n w||_2^2}{2\sigma_1^2}\right) + \log\left(\frac{1}{\sqrt{2\pi\sigma_2^2}} \exp\left(\frac{||(w_n)||_2^2}{2\sigma_2^2}\right)\right)\right)$$

$$\Rightarrow \max_{w} = \frac{||y - Xw||_2^2}{2\sigma_1^2} - \frac{||w||_2^2}{2\sigma_2^2}$$

$$\Rightarrow \min_{w} = \frac{||y - Xw||_2^2}{} - \frac{\sigma_1^2}{\sigma_2^2} ||w||_2^2$$

maximizar algo negativo es minimizar

$$\cos(\theta_{xy}) = \frac{\langle X, Y \rangle}{\|X\|_2 \|Y\|_2}$$

$$\rho(X,Y) = \frac{cov(X,Y)}{\sqrt{var(X^2)\, var(Y)^2}}$$

Hilbert (L_2)

Producto punto bien definido según Hilbert.

$\phi(a)^T \phi(b)$

Producto interno

$\langle \phi(a), \phi(b) \rangle$

$\|\phi(a)\|_2 = \sqrt{\langle \phi(a), \phi(a) \rangle}$

distancia

$d(\phi(a), \phi(b)) = \|\phi(a) - \phi(b)\|_2$

$\varepsilon(\phi(a), \phi(b)) = \|\phi(a) - \phi(b)\|_2^2$

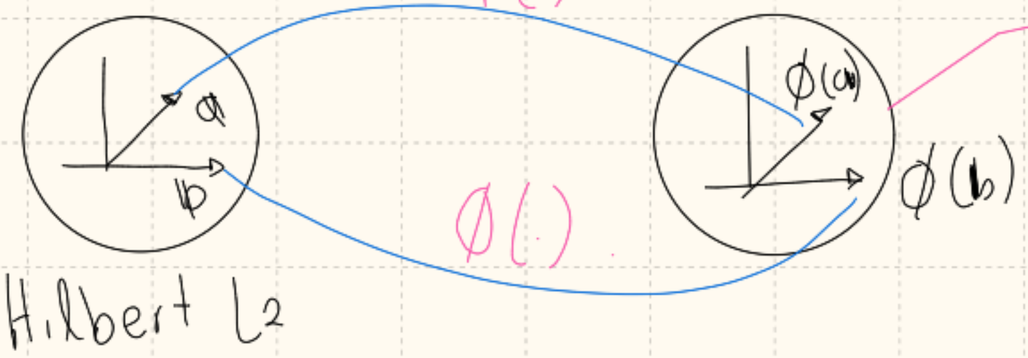
$= \langle \phi(a) - a(b), \phi(a) - \phi(b) \rangle$

$= (\phi(a) - \phi(b))^T (\phi(a) - a(b))$

$= \|\phi(a)\|_2^2 - 2\langle \phi(a), \phi(b) \rangle + \|\phi(b)\|_2^2$

$\cos_{\phi a \phi b}(\theta) = \frac{\langle \phi(a), \phi(b) \rangle}{\|\phi(a)\|_2 \, \|a(b)\|_2}$

Kernels



Revisar los 4 criterios de Hilbert.

$X \in \mathbb{R}^{N \times P}$

$\phi : \mathbb{R}^{N \times P} \longrightarrow \mathbb{R}^{N \times \Phi}$

$Q \to \infty \;\Big|\; P << Q$

$P >> Q$

ahora: $X \in \mathbb{R}^{N \times P}$

$\phi(X) \in \mathbb{R}^{N \times Q}$

$\Phi >> P$

$\Phi \to \infty$

$$\phi(X)^T \phi(X) = \langle \phi(X), \phi(X) \rangle \quad \star$$

$Q \times N \quad N \times Q$

$Q \times \Phi \to \infty \times \infty$

Descomposición en valores singulares. (SVD)? $X = USV^T$

Que relación tienen los valores singulares con las filas independientes

si tengo 3 Ecuaciones → 3 Var ⇒ 3

70 Ec... → 3 Var ⇒ 3

2 Ec... → 3 Var → 2

$N \times \emptyset$

$N, \emptyset \Rightarrow \emptyset$

$N >> \emptyset \Rightarrow \emptyset$

$N << \emptyset \Rightarrow N$

$R(\min(N, \emptyset))$

$\max(\min(N, \emptyset))$.

$\Rightarrow X = U S V^T$

$N \times p \quad N \times N \quad N \times p \quad p \times p$

$\Rightarrow$ de ☆ $\Phi(X) = U S V^T$

$N \times \emptyset \quad N \times N \quad N \times \emptyset \quad \emptyset \times \emptyset$

→ ∘ $\Phi^T(X)\Phi(X) = (USV^T)^T(USV^T)$

$= VV S^T U^T USV^T$

$= V \underbrace{S^T S}_{\emptyset \times \emptyset} V^T$

∘ $\Phi(X)\Phi^T(X) = (USV)^T(USV^T)^T$

$N \times N = USV^T VS^T U^T$

$\underbrace{\quad}_{I}$

$U S S^T U^T$

$\underbrace{\quad}_{N \times N}$

$S = \begin{bmatrix} 7 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 3 \\ 0 & 0 & 0 \end{bmatrix}_{4 \times 3}$

$S^T S = 3 \times 3 \begin{bmatrix} 7 & 0 & 0 \\ 0 & 4 & 0 \\ 0 & 0 & 9 \end{bmatrix}$

infinitas filas y columnas

$\begin{bmatrix} 7 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 4 & 0 & 0 & & \\ 0 & 0 & 9 & 0 & & \\ 0 & 0 & 0 & 0 & & \\ \vdots & & & & \ddots & \\ 0 & & & & & 0 \end{bmatrix}$

Al ser completamente ceros.

$$\phi^T(x)\phi(x) \overset{\Delta}{=} \phi(x)\phi^T(x)$$