Fundamentos Matemáticos y Geométricos para el Aprendizaje de Máquina

De la Probabilidad y el Álgebra Lineal a los Espacios de Hilbert, Mínimos Cuadrados y Kernels

Basado estrictamente en los apuntes manuscritos de clase

30 de septiembre de 2026

Resumen

Este documento constituye la transcripción rigurosa, completa y estructurada de los apuntes manuscritos de la materia. Se desarrollan paso a paso, sin omitir etapas algebraicas ni alterar la notación fijada en clase, los fundamentos que vinculan la teoría de probabilidades con el álgebra lineal y la geometría de espacios de Hilbert. El recorrido inicia en las reglas de probabilidad y el Teorema de Bayes; progresa hacia el valor esperado, momentos y la geometría de L_2; formaliza la vectorización con vectores de unos y matrices de covarianza de datos; demuestra analíticamente los momentos de la distribución Gaussiana y la estimación por Máxima Verosimilitud (MLE); deduce matricialmente la Regresión Lineal por Mínimos Cuadrados Ordinarios (OLS) y Regularizados (Ridge); demuestra la conexión probabilística exacta entre MLE/MAP y Mínimos Cuadrados; y concluye con la formulación de Kernels en espacios de Hilbert y su dualidad espectral mediante la Descomposición en Valores Singulares (SVD).

Índice

1. Probabilidad, Variables Aleatorias y Teorema de Bayes **4**
1.1. Tabla de Contingencia y Reglas Fundamentales 4
1.2. Cantidad de Información de Shannon 4
1.3. Teorema de Bayes 5
1.4. Variables Discretas vs. Variables Continuas 5

2. Valor Esperado y Geometría en Espacios de Hilbert (L_2) **6**
2.1. Esperanza Matemática y Muestras i.i.d. 6
2.2. Estructura de un Espacio de Hilbert en L_2 6
2.2.1. Convención Estricta de Vectores y Transpuesta 6
2.2.2. Norma y Distancia Métrica 6
2.3. Demostración: Producto Interno y Ley de Cosenos 7

3. Momentos Estadísticos, Centrado y la Conexión Geométrica **8**
3.1. Momentos y Centrado 8
3.2. Demostración de la Varianza 8
3.3. Demostración de la Covarianza 8
3.4. Índice de Correlación de Pearson y Equivalencia Geométrica 8
3.5. Extensión a Vectores Aleatorios 9

4. Vectorización de Sumatorias Mediante Vectores de Unos **10**
4.1. Vector de Unos $\mathbf{1}$ . . . 10
4.2. Sumatoria de Vectores . . . 10
4.3. Sumatoria en Matrices . . . 10

5. Matriz de Datos, Centrado, Covarianza y Pearson Matricial **11**
5.1. Matriz de Datos y Vectores de Promedio . . . 11
5.2. Centrado Matricial . . . 11
5.3. Matrices de Covarianza y Matriz de Gram . . . 11
5.4. Cálculo Matricial de Pearson sin División Matricial . . . 12
5.5. Ejemplo Resuelto: Matriz de Datos 3×2 . . . 12
5.6. Aplicación a Imágenes y la Solución de Ingeniería con ε . . . 13

6. Distribución Gaussiana y Demostración Rigurosa de Momentos **14**
6.1. Definición de la Densidad Normal . . . 14
6.2. Demostración: Primer Momento $E[X] = \mu$ . . . 14
6.3. Demostración: Segundo Momento $E[X^2] = \sigma^2 + \mu^2$ . . . 15
6.4. Demostración: Varianza $\mathrm{Var}(X) = \sigma^2$ . . . 15

7. Estimación por Máxima Verosimilitud (MLE) **16**
7.1. Muestra Gaussiana i.i.d. y Función de Verosimilitud . . . 16
7.2. Transformación Logarítmica . . . 16
7.3. Deducción del Estimador de la Media $\hat{\mu}_{\mathrm{MLE}}$ . . . 16
7.4. Deducción del Estimador de la Varianza $\hat{\sigma}^2_{\mathrm{MLE}}$ . . . 17

8. Regresión Lineal: Mínimos Cuadrados Ordinarios (OLS) y Regularizados (Ridge) **18**
8.1. Planteamiento del Modelo Lineal y Error Residual . . . 18
8.2. Deducción Matricial de Mínimos Cuadrados Ordinarios (OLS) . . . 18
8.3. Deducción Matricial de Mínimos Cuadrados Regularizados (Ridge) . . . 18

9. La Conexión Probabilística: De MLE y MAP a Mínimos Cuadrados **20**
9.1. Teorema de Bayes para Inferencia de Parámetros . . . 20
9.2. Caso 1: MLE Equivale a Mínimos Cuadrados Ordinarios . . . 20
9.3. Caso 2: MAP Equivale a Mínimos Cuadrados Regularizados (Ridge) . . . 21

10. Kernels en Espacios de Hilbert (L_2) y Descomposición SVD **22**
10.1. Transformación No Lineal a Espacios de Hilbert . . . 22
10.2. Matriz de Características vs. Matriz de Gram . . . 22
10.3. Descomposición en Valores Singulares (SVD) y Rango . . . 22
10.4. Dualidad Espectral entre $\Phi(X)^\top\Phi(X)$ y $\Phi(X)\Phi(X)^\top$ . . . 23

11. Geometría en Espacios de Hilbert ($\mathcal{L}_2$), Vectorización del Kernel RBF y Operador de Covarianza en RKHS **23**
11.1. Geometría en Espacios de Hilbert ($\mathcal{L}_2$) y Espacios Proyectados por $\phi(X)$ . . . 23
11.2. Matriz de Distancias y Vectorización del Kernel RBF . . . 25
11.2.1. Descomposición Analítica de la Norma Euclídea . . . 25
11.2.2. Construcción Matricial sin Bucles mediante $\mathbf{1}_N$ . . . 25
11.2.3. Evaluación del Kernel y Análisis Asintótico de σ^2 . . . 26
11.3. Demostración Algebraico-Matricial de la Covarianza Muestral en $\phi(X)$ . . . 26
11.3.1. Definición de Momentos y Alineación Dimensional . . . 26
11.3.2. Expansión Paso a Paso y Simplificación de Términos Cruzados . . . 27

11.4. Resolución del Reto de la Página 45: Deducción Matricial Pura sin Pasar por la Versión Escalar 28
11.4.1. Definición y Propiedades de la Matriz de Centrado H 28
11.4.2. Centrado Matricial Directo en el Espacio de Hilbert 29
11.4.3. Deducción de la Matriz de Gram Centrada K_c 29
11.4.4. Demostración de Equivalencia con la Expresión de Traza 29
11.4.5. El Operador de Covarianza en Espacios RKHS de Dimensión Infinita . . . 30

1. Probabilidad, Variables Aleatorias y Teorema de Bayes

1.1. Tabla de Contingencia y Reglas Fundamentales

El punto de partida de la probabilidad discreta se fundamenta en la observación conjunta de dos variables aleatorias X e Y mediante una tabla de frecuencias o contingencia.

Consideremos N observaciones totales distribuidas en una grilla donde las filas representan los estados de Y ($Y = y_i$, con índice de fila i) y las columnas representan los estados de X ($X = x_j$, con índice de columna j):

- n_{ij}: número de observaciones donde simultáneamente ocurren $X = x_j$ e $Y = y_i$.
- $c_j = \sum_i n_{ij}$: suma de los datos de la columna j.
- $r_i = \sum_j n_{ij}$: suma de los datos de la fila i.
- $N = \sum_i \sum_j n_{ij}$: total de observaciones del universo completo.

A partir de estas frecuencias se definen con rigor las probabilidades fundamentales:

Definición 1.1 (Probabilidad Conjunta)**.** *Evalúa un punto específico relativo al universo completo:*

$$p(X = x_j, Y = y_i) = \frac{n_{ij}}{N}. \tag{1}$$

Definición 1.2 (Probabilidades Marginales y Regla de la Suma)**.** *La probabilidad marginal evalúa toda una fila o toda una columna dividida entre el total del universo:*

$$p(X = x_j) = \frac{c_j}{N} = \frac{\sum_i n_{ij}}{N} = \sum_i p(X = x_j, Y = y_i), \tag{2}$$

$$p(Y = y_i) = \frac{r_i}{N} = \frac{\sum_j n_{ij}}{N} = \sum_j p(X = x_j, Y = y_i). \tag{3}$$

Definición 1.3 (Probabilidad Condicional)**.** *Corresponde a evaluar un punto específico limitando el universo a una fila o columna dada:*

$$p(X = x_j \mid Y = y_i) = \frac{n_{ij}}{\sum_j n_{ij}} = \frac{n_{ij}}{r_i}, \tag{4}$$

$$p(Y = y_i \mid X = x_j) = \frac{n_{ij}}{\sum_i n_{ij}} = \frac{n_{ij}}{c_j}. \tag{5}$$

Proposición 1.1 (Regla del Producto)**.** *Multiplicando y dividiendo por la marginal de columna c_j se obtiene la descomposición canónica:*

$$p(X = x_j, Y = y_i) = \frac{n_{ij}}{N} = \frac{n_{ij}}{c_j} \cdot \frac{c_j}{N} = p(Y = y_i \mid X = x_j)\, p(X = x_j). \tag{6}$$

De manera análoga, para las filas r_i:

$$p(Y = y_i, X = x_j) = \frac{n_{ij}}{N} = \frac{n_{ij}}{r_i} \cdot \frac{r_i}{N} = p(X = x_j \mid Y = y_i)\, p(Y = y_i). \tag{7}$$

1.2. Cantidad de Información de Shannon

En términos probabilísticos, la cantidad de información que aporta la ocurrencia de un evento x se define formalmente como:

$$I(x) = -\log_2(p(x)) = \log_2\left(p(x)^{-1}\right) = \log_2\left(\frac{1}{p(x)}\right). \tag{8}$$

- Si $p(x)$ es alta: el evento es común y esperado, por lo tanto contiene **poca información**.
- Si $p(x)$ es baja: el evento es raro e improbable, por lo tanto su ocurrencia aporta **mucha información** (factor de sorpresa).

1.3. Teorema de Bayes

Igualando las dos expresiones obtenidas en la regla del producto para la probabilidad conjunta $p(X = x_j, Y = y_i) = p(Y = y_i, X = x_j)$:

$$p(X = x_j \mid Y = y_i)\, p(Y = y_i) = p(Y = y_i \mid X = x_j)\, p(X = x_j). \tag{9}$$

Despejando directamente se obtiene el Teorema de Bayes:

$$p(X = x_j \mid Y = y_i) = \frac{p(Y = y_i \mid X = x_j)\, p(X = x_j)}{p(Y = y_i)} = \frac{p(Y = y_i \mid X = x_j)\, p(X = x_j)}{\sum_k p(Y = y_i \mid X = x_k)\, p(X = x_k)}. \tag{10}$$

Ejemplo 1.1 (Ejemplo de Urnas y Bolas). Consideremos dos cajas: Caja Azul ($C = C_A$) y Caja Negra ($C = C_N$), que contienen bolas verdes (v) y bolas rojas (r):

- Caja Azul (C_A): 2 bolas verdes y 6 bolas rojas (total 8 bolas).
- Caja Negra (C_N): 5 bolas verdes y 4 bolas rojas (total 9 bolas).

Las probabilidades condicionales directas surgen por simple inspección del contenido de cada caja:

$$p(B = r \mid C = C_A) = \frac{6}{8}, \quad p(B = v \mid C = C_A) = \frac{2}{8}, \quad p(B = v \mid C = C_N) = \frac{5}{9}. \tag{11}$$

Si seleccionamos una caja al azar con $p(C = C_A) = p(C = C_N) = 1/2$ y observamos una bola roja ($B = r$), la probabilidad posterior de que provenga de la Caja Azul se calcula mediante Bayes:

$$p(C = C_A \mid B = r) = \frac{p(B = r \mid C = C_A)\, p(C = C_A)}{p(B = r)}. \tag{12}$$

donde la probabilidad total (marginal) de bola roja es:

$$p(B = r) = p(B = r \mid C = C_A)\, p(C = C_A) + p(B = r \mid C = C_N)\, p(C = C_N) = \frac{6}{8} \cdot \frac{1}{2} + \frac{4}{9} \cdot \frac{1}{2}. \tag{13}$$

1.4. Variables Discretas vs. Variables Continuas

- **Variables discretas:** Se describen mediante la función de masa de probabilidad (PMF):

$$P(X = x_i) = p(x_i), \quad \sum_{i=0}^{N} P(X = x_i) = 1. \tag{14}$$

- **Variables continuas:** Se describen mediante la función de densidad de probabilidad (PDF), $p(x)$:

$$P(a \le X \le b) = \int_a^b p(x)\, dx, \quad \int_{-\infty}^{+\infty} p(x)\, dx = 1. \tag{15}$$

- **Probabilidad de un punto específico:** En una variable continua, la probabilidad exacta en un punto individual es nula:

$$P(X = x) = \int_x^x p(t)\, dt = 0. \tag{16}$$

- **Densidad como derivada diferencial:** En un intervalo diferencial $[x, x + dx]$:

$$P(x \le X \le x+dx) = \int_x^{x+dx} p(t)\, dt = dP(X = x) \implies dP(x) = p(x)\, dx \iff p(x) = \frac{dP(x)}{dx}. \tag{17}$$

  En términos de límite: $\lim_{\Delta x \to 0} \frac{P(x \le X \le x+\Delta x)}{\Delta x} = p(x)$.

2. Valor Esperado y Geometría en Espacios de Hilbert (L_2)

2.1. Esperanza Matemática y Muestras i.i.d.

El valor esperado (media poblacional) de una variable aleatoria se define como:

$$E[X] = \int_{-\infty}^{+\infty} x\, p(x)\, dx \quad \text{(caso continuo)}, \qquad E[X] = \sum_i x_i\, P(X = x_i) \quad \text{(caso discreto)}. \tag{18}$$

Si las observaciones provienen de una muestra de N variables independientes e idénticamente distribuidas (i.i.d.), o bajo una distribución uniforme empírica donde cada punto tiene probabilidad $p(x_i) = \frac{1}{N}$:

$$E[X] \approx \frac{1}{N} \sum_{n=1}^{N} x_n = \mu_X. \tag{19}$$

2.2. Estructura de un Espacio de Hilbert en L_2

Un espacio de Hilbert en L_2 satisface tres condiciones geométricas fundamentales:

1. Existencia de un **producto interno** $\langle \cdot, \cdot \rangle$.
2. Existencia de una **norma inducida** $\| \cdot \|_2 = \sqrt{\langle \cdot, \cdot \rangle}$.
3. Existencia de una **distancia métrica** $d(a, b) = \|a - b\|_2$.

2.2.1. Convención Estricta de Vectores y Transpuesta

En álgebra lineal y aprendizaje computacional:

- Todo vector $a \in \mathbb{R}^P$ se asume por convención como **vector columna** de dimensiones $P \times 1$:

$$a = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_P \end{bmatrix} \in \mathbb{R}^{P \times 1}, \qquad a^\top = \begin{bmatrix} a_1 & a_2 & \cdots & a_P \end{bmatrix} \in \mathbb{R}^{1 \times P} \quad \text{(vector fila)}. \tag{20}$$

- **Producto interno (escalar):** fila por columna da un escalar:

$$\langle a, b \rangle = a^\top b = \sum_{k=1}^{P} a_k b_k \in \mathbb{R}^{1 \times 1}. \tag{21}$$

- **Producto externo (matriz):** columna por fila genera una matriz $P \times P$:

$$ab^\top \in \mathbb{R}^{P \times P}. \tag{22}$$

2.2.2. Norma y Distancia Métrica

La norma se define a partir del producto interno:

$$\|a\|_2 = \sqrt{\langle a, a \rangle} \implies \|a\|_2^2 = \langle a, a \rangle = a^\top a. \tag{23}$$

La distancia euclidiana entre dos vectores a y b cumple la propiedad de simetría $d(a, b) = d(b, a)$:

$$\mathcal{E}(a, b) = d^2(a, b) = \|a - b\|_2^2 = \langle a - b, a - b \rangle. \tag{24}$$

Desarrollando algebraicamente el producto interno:

$$\begin{aligned} \|a - b\|_2^2 &= \langle a - b, a - b \rangle = (a^\top - b^\top)(a - b) \\ &= a^\top a - a^\top b - b^\top a + b^\top b \\ &= \langle a, a \rangle - \langle a, b \rangle - \langle b, a \rangle + \langle b, b \rangle \\ &= \|a\|_2^2 - 2\langle a, b \rangle + \|b\|_2^2. \end{aligned} \tag{25}$$

2.3. Demostración: Producto Interno y Ley de Cosenos

Teorema 2.1. *El producto interno entre dos vectores $a, b \in \mathbb{R}^P$ satisface:*

$$\langle a, b\rangle = \|a\|_2 \, \|b\|_2 \, \cos(\theta_{a,b}), \tag{26}$$

donde $\theta_{a,b}$ es el ángulo convexo formado entre ambos vectores.

Demostración. Consideremos el triángulo vectorial formado por los vectores a, b y el vector diferencia $a - b = a + (-b)$ que cierra el triángulo.

1. Por la **Ley de Cosenos** aplicada a dicho triángulo:

$$\|a - b\|_2^2 = \|a\|_2^2 + \|b\|_2^2 - 2\|a\|_2 \, \|b\|_2 \, \cos(\theta_{a,b}).$$

2. Igualando la expresión geométrica (**??**) con el desarrollo algebraico (25):

$$\|a\|_2^2 - 2\langle a, b\rangle + \|b\|_2^2 = \|a\|_2^2 + \|b\|_2^2 - 2\|a\|_2 \, \|b\|_2 \, \cos(\theta_{a,b}). \tag{28}$$

3. Cancelando los términos comunes $\|a\|_2^2 + \|b\|_2^2$ a ambos lados:

$$-2\langle a, b\rangle = -2\|a\|_2 \, \|b\|_2 \, \cos(\theta_{a,b}). \tag{29}$$

4. Dividiendo entre -2:

$$\langle a, b\rangle = \|a\|_2 \, \|b\|_2 \, \cos(\theta_{a,b}). \tag{30}$$

Despejando el coseno se obtiene la fórmula canónica del ángulo:

$$\cos(\theta_{a,b}) = \frac{\langle a, b\rangle}{\|a\|_2 \, \|b\|_2}. \tag{31}$$

Si los vectores son perpendiculares ($\theta = 90^\circ = \pi/2$), entonces $\cos(90^\circ) = 0 \implies \langle a, b\rangle = 0$. □

Observación 2.1 (Coeficiente de Proyección en Señales). En espacios continuos de funciones (señales $x(t)$ sobre bases ortonormales $u_n(t)$), la proyección ortogonal viene dada por el coeficiente de Fourier generalizado:

$$c_n = \frac{\langle x(t), u_n(t)\rangle}{\|u_n(t)\|_2^2}. \tag{32}$$

3. Momentos Estadísticos, Centrado y la Conexión Geométrica

3.1. Momentos y Centrado

- **Primer momento (Media):** $\mu_X = E[X] \in \mathbb{R}$.
- **Segundo momento no centralizado:** $E[X^2]$. Notar que $\mu_X^2 \neq E[X^2]$.
- **Momento de orden n:** $E[X^n]$.
- **Momento centralizado de orden 1:** Al restar la media a una variable aleatoria se elimina el offset continuo (nivel DC):

$$E[X - \mu_X] = E[X] - E[\mu_X] = \mu_X - \mu_X = 0. \tag{33}$$

Interpretación: Al centralizar dos señales o variables, quedan referenciadas a cero, permitiendo realizar comparaciones directas de forma y variabilidad.

3.2. Demostración de la Varianza

Teorema 3.1. *La varianza de una variable escalar X es* $\mathrm{Var}(X) = E[X^2] - \mu_X^2$.

Demostración. Por definición de momento centralizado de segundo orden:

$$\begin{aligned}
\mathrm{Var}(X) &= E\left[(X - \mu_X)^2\right] = E\left[X^2 - 2\mu_X X + \mu_X^2\right] \\
&= E[X^2] - 2\mu_X E[X] + \mu_X^2 \\
&= E[X^2] - 2\mu_X(\mu_X) + \mu_X^2 \\
&= E[X^2] - 2\mu_X^2 + \mu_X^2 = E[X^2] - \mu_X^2.
\end{aligned} \tag{34}$$

□

3.3. Demostración de la Covarianza

Teorema 3.2. *La covarianza entre dos variables X e Y es* $\mathrm{Cov}(X, Y) = E[XY] - \mu_X \mu_Y$.

Demostración. El momento cruzado centralizado de segundo orden es:

$$\begin{aligned}
\mathrm{Cov}(X, Y) &= E\left[(X - \mu_X)(Y - \mu_Y)\right] \\
&= E\left[XY - \mu_Y X - \mu_X Y + \mu_X \mu_Y\right] \\
&= E[XY] - \mu_Y E[X] - \mu_X E[Y] + \mu_X \mu_Y \\
&= E[XY] - \mu_Y \mu_X - \mu_X \mu_Y + \mu_X \mu_Y \\
&= E[XY] - \mu_X \mu_Y.
\end{aligned} \tag{35}$$

□

Regla conceptual: La Varianza evalúa 1 sola variable; la Covarianza evalúa la relación cruzada entre 2 variables.

3.4. Índice de Correlación de Pearson y Equivalencia Geométrica

El coeficiente de correlación de Pearson normaliza la covarianza dividiendo por las desviaciones estándar:

$$\rho(X, Y) = \frac{\mathrm{Cov}(X, Y)}{\sqrt{\mathrm{Var}(X)\,\mathrm{Var}(Y)}} \in [-1, 1]. \tag{36}$$

Existe una correspondencia geométrica directa e inequívoca entre el álgebra vectorial y la estadística:

$$\boxed{\cos(\theta_{a,b}) = \frac{\langle a, b\rangle}{\|a\|_2 \, \|b\|_2} \quad \longleftrightarrow \quad \rho(X,Y) = \frac{\mathrm{Cov}(X,Y)}{\sqrt{\mathrm{Var}(X)\,\mathrm{Var}(Y)}}} \tag{37}$$

El producto interno entre señales centradas es la covarianza; la norma euclidiana es la desviación estándar; y el coseno del ángulo es exactamente el coeficiente de Pearson.

3.5. Extensión a Vectores Aleatorios

Para un vector aleatorio multidimensional $X \in \mathbb{R}^P$, la media es el vector:

$$\mu_X = E[X] = \begin{bmatrix} E[X_1] \\ E[X_2] \\ \vdots \\ E[X_P] \end{bmatrix} \in \mathbb{R}^{P\times 1}, \qquad E[X - \mu_X] = \mathbf{0} \in \mathbb{R}^{P\times 1}. \tag{38}$$

Al analizar las desviaciones aparecen dos operaciones matriciales distintas:

- **Producto interno (escalar):**

$$E\left[(X-\mu_X)^\top (X-\mu_X)\right] = \sum_{j=1}^{P} \mathrm{Var}(X_j) \in \mathbb{R} \quad \text{(varianza total)}. \tag{39}$$

- **Producto externo (matriz de covarianza):**

$$\Sigma = E\left[(X-\mu_X)(X-\mu_X)^\top\right] \in \mathbb{R}^{P\times P}, \qquad \Sigma_{jk} = \mathrm{Cov}(X_j, X_k). \tag{40}$$

4. Vectorización de Sumatorias Mediante Vectores de Unos

4.1. Vector de Unos 1

Para reemplazar el operador de sumatoria $\sum$ por operaciones puramente matriciales se introduce el vector columna de unos:

$$\mathbf{1}_N = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} \in \mathbb{R}^{N\times 1}, \qquad \mathbf{1}_N^\top = \begin{bmatrix} 1 & 1 & \cdots & 1 \end{bmatrix} \in \mathbb{R}^{1\times N}. \tag{41}$$

4.2. Sumatoria de Vectores

- **Si x es un vector columna ($x \in \mathbb{R}^{N\times 1}$):** La suma se obtiene multiplicando por la izquierda por el vector fila $\mathbf{1}_N^\top$:

$$\sum_{i=1}^{N} x_i = \mathbf{1}_N^\top x = \begin{bmatrix} 1 & 1 & \cdots & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix} \in \mathbb{R}^{1\times 1}. \tag{42}$$

- **Si x es un vector fila ($x \in \mathbb{R}^{1\times N}$):** La suma se obtiene multiplicando por la derecha por el vector columna $\mathbf{1}_N$:

$$\sum_{i=1}^{N} x_i = x\mathbf{1}_N = \begin{bmatrix} x_1 & x_2 & \cdots & x_N \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} \in \mathbb{R}^{1\times 1}. \tag{43}$$

4.3. Sumatoria en Matrices

Dada una matriz $A \in \mathbb{R}^{M\times N}$:

- **Suma total de todos los elementos:**

$$\sum_{i=1}^{M}\sum_{j=1}^{N} A_{ij} = \mathbf{1}_M^\top A \mathbf{1}_N \in \mathbb{R}^{1\times 1}. \tag{44}$$

Dimensiones: $(1\times M)(M\times N)(N\times 1) = 1\times 1$.

- **Suma a lo largo de las columnas (produce vector fila de sumas de cada columna):**

$$\mathbf{1}_M^\top A \in \mathbb{R}^{1\times N}, \qquad (\mathbf{1}_M^\top A)_j = \sum_{i=1}^{M} A_{ij}. \tag{45}$$

- **Suma a lo largo de las filas (produce vector columna de sumas de cada fila):**

$$A\mathbf{1}_N \in \mathbb{R}^{M\times 1}, \qquad (A\mathbf{1}_N)_i = \sum_{j=1}^{N} A_{ij}. \tag{46}$$

5. Matriz de Datos, Centrado, Covarianza y Pearson Matricial

5.1. Matriz de Datos y Vectores de Promedio

Sea $X \in \mathbb{R}^{N\times P}$ una matriz de datos compuesta por N observaciones (filas) y P características o píxeles (columnas):

$$X = \begin{bmatrix} x_{1,1} & x_{1,2} & \cdots & x_{1,P} \\ x_{2,1} & x_{2,2} & \cdots & x_{2,P} \\ \vdots & \vdots & \ddots & \vdots \\ x_{N,1} & x_{N,2} & \cdots & x_{N,P} \end{bmatrix} \in \mathbb{R}^{N\times P}. \tag{47}$$

Se definen dos promedios vectoriales fundamentales:

1. **Promedio a nivel de columna (promedio de cada característica / píxel):**

$$\bar{X}_P = \frac{1}{N}\mathbf{1}_N^\top X \in \mathbb{R}^{1\times P}, \qquad (\bar{X}_P)_p = \frac{1}{N}\sum_{n=1}^{N} X_{n,p}. \tag{48}$$

2. **Promedio a nivel de fila (promedio de cada imagen / observación):**

$$\bar{X}_N = \frac{1}{P}X\mathbf{1}_P \in \mathbb{R}^{N\times 1}, \qquad (\bar{X}_N)_n = \frac{1}{P}\sum_{p=1}^{P} X_{n,p}. \tag{49}$$

5.2. Centrado Matricial

Para centrar los datos restando la media correspondiente:

- **Centrado de columnas (promedio de características restado a cada fila):**

$$X_c = X - \mathbf{1}_N\bar{X}_P = X - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top X \in \mathbb{R}^{N\times P}. \tag{50}$$

  En X_c, cada columna suma idénticamente cero.

- **Centrado de filas (promedio de imagen restado a cada columna):**

$$\hat{X}_c = X - \bar{X}_N\mathbf{1}_P^\top = X - \frac{1}{P}X\mathbf{1}_P\mathbf{1}_P^\top \in \mathbb{R}^{N\times P}. \tag{51}$$

  En $\hat{X}_c$, cada fila suma idénticamente cero.

5.3. Matrices de Covarianza y Matriz de Gram

A partir de la matriz centrada X_c surgen dos productos matriciales distintos:

1. **Matriz de Covarianza muestral de características ($P \times P$):**

$$S = \frac{1}{N}X_c^\top X_c \in \mathbb{R}^{P\times P}. \tag{52}$$

   Compara columnas entre sí. La diagonal $S_{jj} = \mathrm{Var}(X_j)$ contiene las varianzas de cada característica.

2. **Matriz de Gram entre observaciones ($N \times N$):**

$$K = X_cX_c^\top \in \mathbb{R}^{N\times N}. \tag{53}$$

   Compara filas (observaciones/imágenes) entre sí mediante productos internos.

5.4. Cálculo Matricial de Pearson sin División Matricial

Puesto que no existe la división matricial estándar, la normalización de Pearson se resuelve matricialmente de la siguiente manera:

1. Se extrae la diagonal de la matriz de covarianza y se aplica raíz cuadrada para formar el vector columna de desviaciones estándar:

$$v = \sqrt{\operatorname{diag}(S)} = \begin{bmatrix} \sqrt{\operatorname{Var}(X_1)} \\ \sqrt{\operatorname{Var}(X_2)} \\ \vdots \\ \sqrt{\operatorname{Var}(X_P)} \end{bmatrix} \in \mathbb{R}^{P\times 1}. \tag{54}$$

2. La matriz de correlación de Pearson $R \in \mathbb{R}^{P\times P}$ se calcula mediante la división elemento a elemento (división de Hadamard) por el producto externo del vector v:

$$R = \frac{S}{vv^\top} \implies R_{jk} = \frac{S_{jk}}{v_j v_k} = \frac{\operatorname{Cov}(X_j, X_k)}{\sqrt{\operatorname{Var}(X_j)\operatorname{Var}(X_k)}}. \tag{55}$$

5.5. Ejemplo Resuelto: Matriz de Datos 3×2

Ejemplo 5.1. Consideremos $N = 3$ observaciones y $P = 2$ características (ej. peso y altura):

$$X = \begin{bmatrix} 70 & 170 \\ 80 & 180 \\ 90 & 175 \end{bmatrix} \in \mathbb{R}^{3\times 2}. \tag{56}$$

1. **Vector de medias por columnas:**

$$\bar{X}_P = \frac{1}{3}\begin{bmatrix} 1 & 1 & 1 \end{bmatrix}\begin{bmatrix} 70 & 170 \\ 80 & 180 \\ 90 & 175 \end{bmatrix} = \frac{1}{3}\begin{bmatrix} 240 & 525 \end{bmatrix} = \begin{bmatrix} 80 & 175 \end{bmatrix}. \tag{57}$$

2. **Centrado de datos:**

$$X_c = X - \mathbf{1}_3\bar{X}_P = \begin{bmatrix} 70 & 170 \\ 80 & 180 \\ 90 & 175 \end{bmatrix} - \begin{bmatrix} 80 & 175 \\ 80 & 175 \\ 80 & 175 \end{bmatrix} = \begin{bmatrix} -10 & -5 \\ 0 & 5 \\ 10 & 0 \end{bmatrix}. \tag{58}$$

   Notar que $(-10) + 0 + 10 = 0$ y $(-5) + 5 + 0 = 0$.

3. **Matriz de covarianza muestral (usando divisor $N - 1 = 2$):**

$$S = \frac{1}{2}X_c^\top X_c = \frac{1}{2}\begin{bmatrix} -10 & 0 & 10 \\ -5 & 5 & 0 \end{bmatrix}\begin{bmatrix} -10 & -5 \\ 0 & 5 \\ 10 & 0 \end{bmatrix} = \frac{1}{2}\begin{bmatrix} 200 & 50 \\ 50 & 50 \end{bmatrix} = \begin{bmatrix} 100 & 25 \\ 25 & 25 \end{bmatrix}. \tag{59}$$

   Varianzas: $\operatorname{Var}(X_1) = 100 \implies s_1 = 10$; $\operatorname{Var}(X_2) = 25 \implies s_2 = 5$.

4. **Matriz de correlación de Pearson:**

$$R = \begin{bmatrix} \frac{100}{10\cdot 10} & \frac{25}{10\cdot 5} \\ \frac{25}{5\cdot 10} & \frac{25}{5\cdot 5} \end{bmatrix} = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 1 \end{bmatrix}. \tag{60}$$

   El coseno del ángulo es 0.5, correspondiente a $\theta = \arccos(0.5) = 60°$.

5.6. Aplicación a Imágenes y la Solución de Ingeniería con ε

Al aplanar N imágenes de tamaño 28×28, se tiene $X \in \mathbb{R}^{N \times 784}$.

- **Problema de los píxeles muertos:** En datasets como MNIST, los píxeles ubicados en las esquinas y bordes son siempre cero en todas las imágenes. Para dichos píxeles, la varianza matemática es exactamente cero ($\mathrm{Var}(X_j) = 0$).
- **Indeterminación $0/0$:** Al calcular la correlación de un píxel muerto consigo mismo o con otros, la fórmula produce $\frac{0}{0}$.
- **Solución en código con ε:** Para evitar colapsos computacionales por división por cero y garantizar que la diagonal sea idénticamente 1, en programación se introduce una pequeña constante de regularización $\varepsilon = 10^{-6}$ en el denominador:

$$\rho(X_j, X_k) = \frac{\mathrm{Cov}(X_j, X_k)}{\sqrt{\mathrm{Var}(X_j)\,\mathrm{Var}(X_k)} + \varepsilon}. \tag{61}$$

6. Distribución Gaussiana y Demostración Rigurosa de Momentos

6.1. Definición de la Densidad Normal

Una variable aleatoria escalar X con distribución normal $X \sim \mathcal{N}(\mu, \sigma^2)$ tiene como función de densidad de probabilidad:

$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right). \tag{62}$$

Se sabe que $\int_{-\infty}^{+\infty} p(x)\,dx = 1$.

6.2. Demostración: Primer Momento $E[X] = \mu$

Teorema 6.1. *El valor esperado de $X \sim \mathcal{N}(\mu, \sigma^2)$ es $E[X] = \mu$.*

Demostración. Por definición de valor esperado:

$$E[X] = \int_{-\infty}^{+\infty} x \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) dx. \tag{63}$$

Efectuamos el cambio de variable lineal:

$$z = \frac{x-\mu}{\sigma} \implies x = \sigma z + \mu, \qquad dx = \sigma\, dz. \tag{64}$$

Sustituyendo en la integral (los límites se mantienen en $-\infty$ y $+\infty$):

$$\begin{aligned} E[X] &= \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{+\infty} (\sigma z + \mu) \exp\left(-\frac{z^2}{2}\right) \sigma\, dz \\ &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} (\sigma z + \mu) \exp\left(-\frac{z^2}{2}\right) dz \\ &= \frac{\sigma}{\sqrt{2\pi}} \underbrace{\int_{-\infty}^{+\infty} z \exp\left(-\frac{z^2}{2}\right) dz}_{I_1} + \mu \underbrace{\frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} \exp\left(-\frac{z^2}{2}\right) dz}_{I_2}. \end{aligned} \tag{65}$$

Analizamos cada integral por separado:

1. $I_1 = \int_{-\infty}^{+\infty} z \exp\left(-\frac{z^2}{2}\right) dz$: La función $f(z) = z\exp(-z^2/2)$ es una **función impar** ($f(-z) = -f(z)$), y el integrando decae rápidamente al infinito. Por lo tanto, la integral sobre un intervalo simétrico se anula idénticamente:

$$I_1 = 0. \tag{66}$$

   (También puede verificarse sustituyendo $u = -z^2/2 \implies du = -z\,dz$).

2. I_2: Corresponde a la integral de la densidad de una normal estándar $\mathcal{N}(0,1)$, la cual integra exactamente uno:

$$\frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} \exp\left(-\frac{z^2}{2}\right) dz = 1. \tag{67}$$

Sustituyendo ambos resultados:

$$E[X] = \frac{\sigma}{\sqrt{2\pi}}(0) + \mu(1) = \mu. \tag{68}$$

□

6.3. Demostración: Segundo Momento $E[X^2] = \sigma^2 + \mu^2$

Teorema 6.2. *El segundo momento de* $X \sim \mathcal{N}(\mu, \sigma^2)$ *es* $E[X^2] = \sigma^2 + \mu^2$.

Demostración. Por definición:

$$E[X^2] = \int_{-\infty}^{+\infty} x^2 \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) dx. \tag{69}$$

Aplicamos el mismo cambio de variable $x = \sigma z + \mu \implies x^2 = \sigma^2 z^2 + 2\sigma\mu z + \mu^2$, con $dx = \sigma\, dz$:

$$\begin{aligned} E[X^2] &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} (\sigma^2 z^2 + 2\sigma\mu z + \mu^2) \exp\left(-\frac{z^2}{2}\right) dz \\ &= \frac{\sigma^2}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} z^2 \exp\left(-\frac{z^2}{2}\right) dz + \frac{2\sigma\mu}{\sqrt{2\pi}} \underbrace{\int_{-\infty}^{+\infty} z \exp\left(-\frac{z^2}{2}\right) dz}_{=0 \text{ (función impar)}} + \mu^2 \underbrace{\frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} \exp\left(-\frac{z^2}{2}\right) dz}_{=1} \\ &= \frac{\sigma^2}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} z^2 \exp\left(-\frac{z^2}{2}\right) dz + 0 + \mu^2. \end{aligned} \tag{70}$$

Para resolver la integral restante $J = \int_{-\infty}^{+\infty} z^2 \exp(-z^2/2)\, dz$, escribimos $z^2 \exp(-z^2/2) = z \cdot [z \exp(-z^2/2)]$ y aplicamos **integración por partes**:

$$u = z \implies du = dz, \tag{71}$$

$$dv = z \exp\left(-\frac{z^2}{2}\right) dz \implies v = -\exp\left(-\frac{z^2}{2}\right). \tag{72}$$

Aplicando la fórmula de partes $\int u\, dv = uv - \int v\, du$:

$$\begin{aligned} J &= \left[-z \exp\left(-\frac{z^2}{2}\right)\right]_{-\infty}^{+\infty} - \int_{-\infty}^{+\infty} \left(-\exp\left(-\frac{z^2}{2}\right)\right) dz \\ &= \left(\lim_{z\to+\infty} \frac{-z}{e^{z^2/2}} - \lim_{z\to-\infty} \frac{-z}{e^{z^2/2}}\right) + \int_{-\infty}^{+\infty} \exp\left(-\frac{z^2}{2}\right) dz. \end{aligned} \tag{73}$$

Por la regla de L'Hôpital, el término entre corchetes es cero $(0 - 0 = 0)$. Por ende:

$$J = \int_{-\infty}^{+\infty} \exp\left(-\frac{z^2}{2}\right) dz = \sqrt{2\pi}. \tag{74}$$

Sustituyendo J en la expresión de $E[X^2]$:

$$E[X^2] = \frac{\sigma^2}{\sqrt{2\pi}}(\sqrt{2\pi}) + \mu^2 = \sigma^2 + \mu^2. \tag{75}$$

□

6.4. Demostración: Varianza $\mathrm{Var}(X) = \sigma^2$

Utilizando los dos teoremas anteriores:

$$\mathrm{Var}(X) = E[X^2] - (E[X])^2 = (\sigma^2 + \mu^2) - (\mu)^2 = \sigma^2. \tag{76}$$

7. Estimación por Máxima Verosimilitud (MLE)

7.1. Muestra Gaussiana i.i.d. y Función de Verosimilitud

Consideremos N observaciones independientes e idénticamente distribuidas (i.i.d.) $X = [x_1, x_2, \ldots, x_N]^\top$, con $x_n \sim \mathcal{N}(\mu, \sigma^2)$. La densidad conjunta (verosimilitud) se expresa como el producto de densidades individuales:

$$p(X \mid \mu, \sigma^2) = \prod_{n=1}^{N} \mathcal{N}(x_n \mid \mu, \sigma^2) = \prod_{n=1}^{N} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_n - \mu)^2}{2\sigma^2}\right). \tag{77}$$

Buscamos los parámetros $(\hat{\mu}, \hat{\sigma}^2)$ que maximizan la probabilidad de haber observado los datos:

$$(\hat{\mu}_{\text{MLE}}, \hat{\sigma}^2_{\text{MLE}}) = \arg\max_{\mu,\sigma^2} p(X \mid \mu, \sigma^2). \tag{78}$$

7.2. Transformación Logarítmica

Dado que el logaritmo natural $\ln(\cdot)$ es una función estrictamente creciente:

$$\arg\max p(X) = \arg\max \ln p(X). \tag{79}$$

El logaritmo transforma la productoria en una sumatoria y no altera la ubicación del valor óptimo. Desarrollando la log-verosimilitud $\ell(\mu, \sigma^2) = \ln p(X \mid \mu, \sigma^2)$:

$$\begin{aligned}
\ell(\mu, \sigma^2) &= \sum_{n=1}^{N} \ln\left[\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_n - \mu)^2}{2\sigma^2}\right)\right] \\
&= \sum_{n=1}^{N} \left[-\frac{1}{2}\ln(2\pi\sigma^2) - \frac{(x_n - \mu)^2}{2\sigma^2}\right] \\
&= -\frac{N}{2}\ln(2\pi) - \frac{N}{2}\ln(\sigma^2) - \frac{1}{2\sigma^2}\sum_{n=1}^{N}(x_n - \mu)^2.
\end{aligned} \tag{80}$$

7.3. Deducción del Estimador de la Media $\hat{\mu}_{\text{MLE}}$

Derivando parcialmente ℓ respecto de μ e igualando a cero:

$$\begin{aligned}
\frac{\partial \ell}{\partial \mu} &= \frac{\partial}{\partial \mu}\left[-\frac{1}{2\sigma^2}\sum_{n=1}^{N}(x_n - \mu)^2\right] \\
&= -\frac{1}{2\sigma^2}\sum_{n=1}^{N} 2(x_n - \mu)(-1) \\
&= \frac{1}{\sigma^2}\sum_{n=1}^{N}(x_n - \mu) = 0.
\end{aligned} \tag{81}$$

Multiplicando por σ^2:

$$\sum_{n=1}^{N}(x_n - \mu) = 0 \implies \sum_{n=1}^{N} x_n - N\mu = 0 \implies \boxed{\hat{\mu}_{\text{MLE}} = \frac{1}{N}\sum_{n=1}^{N} x_n} \tag{82}$$

El estimador de máxima verosimilitud de la media coincide rigurosamente con la media muestral aritmética.

7.4. Deducción del Estimador de la Varianza $\hat{\sigma}^2_{\text{MLE}}$

Para derivar respecto de la varianza, definimos la variable auxiliar $s = \sigma^2$:

$$\ell(\mu, s) = -\frac{N}{2}\ln(2\pi) - \frac{N}{2}\ln(s) - \frac{1}{2s}\sum_{n=1}^{N}(x_n - \mu)^2. \tag{83}$$

Derivando respecto de s e igualando a cero:

$$\frac{\partial \ell}{\partial s} = -\frac{N}{2s} + \frac{1}{2s^2}\sum_{n=1}^{N}(x_n - \mu)^2 = 0. \tag{84}$$

Multiplicando toda la ecuación por $2s^2$:

$$-Ns + \sum_{n=1}^{N}(x_n - \mu)^2 = 0 \implies Ns = \sum_{n=1}^{N}(x_n - \mu)^2. \tag{85}$$

Sustituyendo $\hat{\mu}_{\text{MLE}}$:

$$\boxed{\hat{\sigma}^2_{\text{MLE}} = \frac{1}{N}\sum_{n=1}^{N}(x_n - \hat{\mu}_{\text{MLE}})^2} \tag{86}$$

8. Regresión Lineal: Mínimos Cuadrados Ordinarios (OLS) y Regularizados (Ridge)

8.1. Planteamiento del Modelo Lineal y Error Residual

Consideremos un modelo de regresión lineal multivariado con ruido aditivo:

$$y = f(x) + \varepsilon \implies y = Xw + \varepsilon, \tag{87}$$

con dimensiones estrictas:

- $y \in \mathbb{R}^{N\times 1}$: vector columna de N respuestas u observaciones objetivo.
- $X \in \mathbb{R}^{N\times P}$: matriz de diseño de N observaciones y P características.
- $w \in \mathbb{R}^{P\times 1}$: vector columna de parámetros (pesos del modelo).
- $\varepsilon \in \mathbb{R}^{N\times 1}$: vector de perturbaciones o ruido.

El modelo predice $\hat{y} = X\hat{w}$. El error residual es $e = y - Xw$.

8.2. Deducción Matricial de Mínimos Cuadrados Ordinarios (OLS)

Para que el error sea mínimo, se plantea minimizar la norma euclidiana al cuadrado del vector de error:

$$\min_{w} \|y - Xw\|_2^2. \tag{88}$$

Desarrollando algebraicamente mediante producto interno:

$$\begin{aligned} J(w) &= \|y - Xw\|_2^2 = \langle y - Xw, y - Xw\rangle = (y - Xw)^\top (y - Xw) \\ &= (y^\top - w^\top X^\top)(y - Xw) \\ &= y^\top y - y^\top Xw - w^\top X^\top y + w^\top X^\top Xw. \end{aligned} \tag{89}$$

Dado que $y^\top Xw$ es un escalar (1×1), es idéntico a su transpuesta: $(y^\top Xw)^\top = w^\top X^\top y$. Por tanto:

$$J(w) = y^\top y - 2y^\top Xw + w^\top X^\top Xw. \tag{90}$$

Derivando respecto al vector de pesos w e igualando a cero:

$$\frac{\partial J}{\partial w} = -2X^\top y + 2X^\top Xw = \mathbf{0}. \tag{91}$$

Dividiendo entre 2 y reordenando:

$$X^\top Xw = X^\top y. \tag{92}$$

Asumiendo que $X^\top X$ es no singular (invertible), multiplicamos por la izquierda por $(X^\top X)^{-1}$:

$$\boxed{\hat{w}_{\text{OLS}} = (X^\top X)^{-1} X^\top y} \tag{93}$$

8.3. Deducción Matricial de Mínimos Cuadrados Regularizados (Ridge)

Cuando la matriz de datos presenta ruido, alta correlación entre columnas (multicolinealidad) o $P > N$, la matriz $X^\top X$ se vuelve mal condicionada o singular (los mínimos cuadrados ordinarios colapsan). Para estabilizar la solución se penaliza la magnitud de los pesos:

$$\min_{w} \|y - Xw\|_2^2 + \lambda \|w\|_2^2, \quad \lambda > 0. \tag{94}$$

Desarrollando la función de costo regularizada $J_{\text{Ridge}}(w)$:

$$J_{\text{Ridge}}(w) = y^\top y - 2y^\top Xw + w^\top X^\top Xw + \lambda w^\top w = y^\top y - 2y^\top Xw + w^\top (X^\top X + \lambda I)w. \quad (95)$$

Derivando respecto a w e igualando a cero:

$$\frac{\partial J_{\text{Ridge}}}{\partial w} = -2X^\top y + 2X^\top Xw + 2\lambda w = \mathbf{0}. \quad (96)$$

Factorizando el vector w:

$$(X^\top X + \lambda I)w = X^\top y. \quad (97)$$

Puesto que $\lambda > 0$, la matriz $(X^\top X + \lambda I)$ es estrictamente simétrica y definida positiva (siempre invertible). Multiplicando por la inversa:

$$\boxed{\hat{w}_{\text{Ridge}} = (X^\top X + \lambda I)^{-1} X^\top y} \quad (98)$$

Observación 8.1 (Condición de Frontera). Si $\lambda = 0$, la formulación regularizada recupera exactamente los mínimos cuadrados ordinarios:

$$\text{MC} \equiv \text{MCR}(\lambda = 0). \quad (99)$$

9. La Conexión Probabilística: De MLE y MAP a Mínimos Cuadrados

9.1. Teorema de Bayes para Inferencia de Parámetros

En el aprendizaje de máquina probabilístico, el Teorema de Bayes se formula para inferir un conjunto de parámetros desconocidos θ a partir de datos observados x:

$$p(\theta \mid x) = \frac{p(x \mid \theta)\, p(\theta)}{p(x)}, \tag{100}$$

donde:

- $p(\theta)$: **Distribución a priori (Prior)**, creencia inicial sobre los parámetros antes de observar los datos.
- $p(x \mid \theta)$: **Verosimilitud (Likelihood)**, qué tan probables son los datos observados bajo los parámetros θ.
- $p(x) = \int p(x \mid \theta)\, p(\theta)\, d\theta$: **Evidencia marginal**, probabilidad total de los datos.
- $p(\theta \mid x)$: **Distribución a posteriori (Posterior)**, creencia actualizada de los parámetros tras observar los datos.

9.2. Caso 1: MLE Equivale a Mínimos Cuadrados Ordinarios

Asumamos el modelo lineal $y = Xw + \varepsilon$, donde el ruido sigue una distribución Gaussiana centrada:

$$\varepsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2 I_N). \tag{101}$$

En este escenario, w se considera un parámetro constante desconocido (sin distribución a priori). Por ende, condicionado a X y w, el vector objetivo y sigue una distribución Gaussiana:

$$y \mid X, w \sim \mathcal{N}(Xw, \sigma^2 I_N). \tag{102}$$

La verosimilitud de las N observaciones independientes es:

$$p(y \mid X, w) = \prod_{n=1}^{N} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_n - x_n w)^2}{2\sigma^2} \right). \tag{103}$$

Tomando el logaritmo natural:

$$\ln p(y \mid X, w) = -\frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{n=1}^{N} (y_n - x_n w)^2 = -\frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \|y - Xw\|_2^2. \tag{104}$$

Para maximizar respecto a w, el término constante $-\frac{N}{2}\ln(2\pi\sigma^2)$ no interviene, y maximizar un término negativo equivale a minimizar su opuesto positivo:

$$\arg\max_w \ln p(y \mid X, w) = \arg\max_w \left[-\frac{1}{2\sigma^2} \|y - Xw\|_2^2 \right] = \arg\min_w \|y - Xw\|_2^2. \tag{105}$$

Conclusión fundamental: El estimador de Máxima Verosimilitud (MLE) bajo ruido Gaussiano coincide de manera exacta e idéntica con el estimador de Mínimos Cuadrados Ordinarios (OLS).

9.3. Caso 2: MAP Equivale a Mínimos Cuadrados Regularizados (Ridge)

Ahora consideramos el enfoque Bayesiano donde el vector de pesos w no es una constante fija, sino una variable aleatoria que sigue una distribución a priori Gaussiana centrada:

$$w \sim \mathcal{N}(\mathbf{0}, \sigma_w^2 I_P) \implies p(w) = \frac{1}{(2\pi\sigma_w^2)^{P/2}} \exp\left(-\frac{\|w\|_2^2}{2\sigma_w^2}\right). \tag{106}$$

Por el Teorema de Bayes, la distribución a posteriori sobre los pesos es:

$$p(w \mid y, X) = \frac{p(y \mid X, w)\, p(w)}{p(y \mid X)} \propto p(y \mid X, w)\, p(w). \tag{107}$$

El estimador de Máximo a Posteriori (MAP) busca maximizar el logaritmo del producto:

$$\begin{aligned} \ln p(w \mid y, X) &= \ln p(y \mid X, w) + \ln p(w) + \text{constante} \\ &= \left(-\frac{1}{2\sigma^2}\|y - Xw\|_2^2\right) + \left(-\frac{1}{2\sigma_w^2}\|w\|_2^2\right) + \text{constante}. \end{aligned} \tag{108}$$

Maximizar esta cantidad negativa equivale estrictamente a minimizar la suma positiva:

$$\arg\max_w \ln p(w \mid y, X) = \arg\min_w \left[\frac{1}{2\sigma^2}\|y - Xw\|_2^2 + \frac{1}{2\sigma_w^2}\|w\|_2^2\right]. \tag{109}$$

Multiplicando toda la expresión objetivo por el escalar positivo $2\sigma^2$:

$$\arg\min_w \left[\|y - Xw\|_2^2 + \frac{\sigma^2}{\sigma_w^2}\|w\|_2^2\right]. \tag{110}$$

Comparando término a término con la función de costo de Ridge:

$$\min_w \left[\|y - Xw\|_2^2 + \lambda\|w\|_2^2\right], \tag{111}$$

se comprueba rigurosamente que la regularización Ridge equivale exactamente a inferencia MAP bajo un prior Gaussiano, donde el parámetro de regularización λ surge como la razón entre la varianza del ruido del sistema y la varianza a priori de los pesos:

$$\boxed{\lambda = \frac{\sigma^2}{\sigma_w^2}} \tag{112}$$

10. Kernels en Espacios de Hilbert (L_2) y Descomposición SVD

10.1. Transformación No Lineal a Espacios de Hilbert

Cuando los datos no son separables o linealmente relacionables en el espacio original $\mathbb{R}^P$, se proyectan a un espacio de Hilbert inducido de dimensionalidad significativamente mayor (o infinita) mediante una función de mapeo no lineal ϕ:

$$\phi : \mathbb{R}^P \to \mathbb{R}^Q, \quad \text{donde } Q \gg P \text{ o } Q \to \infty. \tag{113}$$

Para la matriz de datos completa:

$$X \in \mathbb{R}^{N\times P} \xrightarrow{\phi} \Phi(X) \in \mathbb{R}^{N\times Q}. \tag{114}$$

En dicho espacio de Hilbert inducido (L_2), la geometría se preserva rigurosamente mediante el producto interno:

- **Producto interno:** $\langle \phi(a), \phi(b) \rangle = \phi(a)^\top \phi(b)$.
- **Norma euclidiana inducida:** $\|\phi(a)\|_2 = \sqrt{\langle \phi(a), \phi(a) \rangle}$.
- **Distancia métrica inducida:**

$$\mathcal{E}(\phi(a), \phi(b)) = \|\phi(a) - \phi(b)\|_2^2 = \|\phi(a)\|_2^2 - 2\langle \phi(a), \phi(b) \rangle + \|\phi(b)\|_2^2. \tag{115}$$

- **Coseno del ángulo inducido:**

$$\cos(\theta_{\phi(a),\phi(b)}) = \frac{\langle \phi(a), \phi(b) \rangle}{\|\phi(a)\|_2 \, \|\phi(b)\|_2}. \tag{116}$$

10.2. Matriz de Características vs. Matriz de Gram

A partir del mapeo $\Phi(X)$ aparecen dos matrices:

1. **Matriz de Covarianza en el espacio de Hilbert ($Q \times Q$):**

$$\Phi(X)^\top \Phi(X) \in \mathbb{R}^{Q\times Q}. \tag{117}$$

   Si $Q \to \infty$, esta matriz es de dimensión infinita y resulta incalculable directamente.

2. **Matriz de Gram / Matriz de Kernels ($N \times N$):**

$$K = \Phi(X)\Phi(X)^\top \in \mathbb{R}^{N\times N}, \qquad K_{nm} = \langle \phi(x_n), \phi(x_m) \rangle. \tag{118}$$

   Esta matriz tiene dimensiones finitas $N \times N$ gobernadas exclusivamente por el número de observaciones, independientemente de que Q sea infinito.

10.3. Descomposición en Valores Singulares (SVD) y Rango

Toda matriz $X \in \mathbb{R}^{N\times P}$ admite una Descomposición en Valores Singulares:

$$X = USV^\top, \tag{119}$$

donde $U \in \mathbb{R}^{N\times N}$ y $V \in \mathbb{R}^{P\times P}$ son matrices ortogonales ($U^\top U = I_N$, $V^\top V = I_P$), y $S \in \mathbb{R}^{N\times P}$ es una matriz pseudodiagonal que contiene los valores singulares $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$. El rango de la matriz satisface $\text{Rango}(X) \leq \text{mín}(N, P)$.

10.4. Dualidad Espectral entre $\Phi(X)^\top\Phi(X)$ y $\Phi(X)\Phi(X)^\top$

Aplicando SVD directamente a la matriz mapeada $\Phi(X) = USV^\top$ con $U \in \mathbb{R}^{N\times N}$, $S \in \mathbb{R}^{N\times Q}$ y $V \in \mathbb{R}^{Q\times Q}$:

1. **Desarrollo de la matriz $Q \times Q$:**

$$\begin{aligned}\Phi(X)^\top\Phi(X) &= (USV^\top)^\top(USV^\top)\\ &= VS^\top \underbrace{U^\top U}_{=I_N} SV^\top\\ &= V(S^\top S)V^\top \in \mathbb{R}^{Q\times Q}.\end{aligned} \tag{120}$$

2. **Desarrollo de la matriz de Gram $N \times N$:**

$$\begin{aligned}\Phi(X)\Phi(X)^\top &= (USV^\top)(USV^\top)^\top\\ &= US\underbrace{V^\top V}_{=I_Q} S^\top U^\top\\ &= U(SS^\top)U^\top \in \mathbb{R}^{N\times N}.\end{aligned} \tag{121}$$

Teorema 10.1 (Equivalencia de Espectros no Nulos)**.** *Las matrices diagonales $S^\top S \in \mathbb{R}^{Q\times Q}$ y $SS^\top \in \mathbb{R}^{N\times N}$ tienen exactamente los mismos elementos diagonales no nulos correspondientes a los cuadrados de los valores singulares:*

$$\sigma_1^2, \sigma_2^2, \ldots, \sigma_r^2, \quad \textit{donde } r \leq \min(N, Q). \tag{122}$$

El resto de sus elementos diagonales son estrictamente ceros.

[Fundamentación del Truco del Kernel] Puesto que ambas matrices comparten idénticos valores propios no nulos:

$$\Phi(X)^\top\Phi(X) \overset{\Delta}{\equiv} \Phi(X)\Phi(X)^\top. \tag{123}$$

Cualquier algoritmo lineal (como regresión, PCA o clasificación) cuya solución dependa del espectro de covarianza puede resolverse de forma equivalente y exacta operando sobre la matriz de Gram $K = \Phi(X)\Phi(X)^\top \in \mathbb{R}^{N\times N}$. Esto permite trabajar computacionalmente en espacios de dimensión infinita evaluando únicamente productos internos finitos entre pares de muestras (**Kernel Trick**).

11. Geometría en Espacios de Hilbert ($\mathcal{L}_2$), Vectorización del Kernel RBF y Operador de Covarianza en RKHS

11.1. Geometría en Espacios de Hilbert ($\mathcal{L}_2$) y Espacios Proyectados por $\phi(X)$

En el espacio euclídeo fundamental $\mathcal{L}_2$, la estructura geométrica entre observaciones se encuentra unívocamente determinada por el producto interno. Para dos vectores de datos $X, X' \in \mathbb{R}^P$, se establecen las definiciones métricas canónicas:

1. **Producto interno:** Mide la proyección y alineación direccional entre los vectores:

$$\langle X, X'\rangle = X^\top X' \in \mathbb{R}. \tag{124}$$

2. **Norma inducida por el producto interno:** Cuantifica la magnitud o longitud euclídea:

$$\|X\|_2 = \sqrt{\langle X, X\rangle} \quad \Longrightarrow \quad \|X\|_2^2 = \langle X, X\rangle = X^\top X \in \mathbb{R}. \tag{125}$$

3. **Métrica de distancia:** Mide la separación euclídea entre ambas observaciones:

$$d(X, X') = \|X - X'\|_2. \tag{126}$$

4. **Distancia al cuadrado ($\mathcal{E}$):** Expandiendo el producto interno de la diferencia:

$$\mathcal{E}(X, X') = d^2(X, X') = \|X - X'\|_2^2 = \langle X - X', X - X' \rangle = \|X\|_2^2 - 2\langle X, X' \rangle + \|X'\|_2^2. \tag{127}$$

Mapeo no lineal al espacio inducido. Consideremos ahora la transformación de la matriz de datos original hacia un espacio de características de Hilbert de dimensión arbitraria o infinita mediante el mapeo no lineal:

$$\phi(\cdot) : \mathbb{R}^{N \times P} \longrightarrow \mathbb{R}^{N \times Q}, \quad \text{con } Q \to \infty. \tag{128}$$

En el espacio proyectado $\phi(X)$, las propiedades métricas se trasladan preservando la estructura euclídea:

1. **Producto interno proyectado (Truco del Kernel):**

$$\langle \phi(X), \phi(X') \rangle = \phi(X)\phi^\top(X') = K(X, X') \in \mathbb{R}^{N \times N}. \tag{129}$$

2. **Norma inducida en el espacio proyectado:**

$$\|\phi(X)\|_2 = \sqrt{\langle \phi(X), \phi(X) \rangle} = \sqrt{K(X, X)}. \tag{130}$$

3. **Distancia euclídea inducida en Hilbert:**

$$d(\phi(X), \phi(X')) = \|\phi(X) - \phi(X')\|_2. \tag{131}$$

4. **Distancia al cuadrado en el espacio de Hilbert:**

$$\mathcal{E}(\phi(X), \phi(X')) = d^2(\phi(X), \phi(X')) = K(X, X) - 2K(X, X') + K(X', X'). \tag{132}$$

5. **Coseno del ángulo inducido (Similitud direccional):**

$$\cos(\theta_H) = \frac{\langle \phi(X), \phi(X') \rangle}{\|\phi(X)\|_2 \|\phi(X')\|_2} = \frac{K(X, X')}{\sqrt{K(X, X)K(X', X')}}. \tag{133}$$

Esta formulación geométrica es formalmente equivalente al coeficiente de correlación de Pearson:

$$\rho(X, X') = \frac{\text{cov}(X, X')}{\sqrt{\text{var}(X)\text{var}(X')}}. \tag{134}$$

En particular, para el Kernel Gaussiano RBF, dado que $K(X_i, X_i) = \exp(0) = 1$ para toda observación, la norma inducida es idénticamente unitaria ($\|\phi(X_i)\|_2 = 1$). En consecuencia:

$$\mathcal{E}(\phi(X), \phi(X')) = 2(1 - K(X, X')), \qquad \cos(\theta_H) = K(X, X'). \tag{135}$$

El valor de afinidad del kernel evalúa directamente el coseno del ángulo entre muestras proyectadas en el espacio de Hilbert.

11.2. Matriz de Distancias y Vectorización del Kernel RBF

Sea $X \in \mathbb{R}^{N\times P}$ la matriz de datos compuesta por N observaciones y P dimensiones, con vectores de muestra $x_i, x_j \in \mathbb{R}^P$ ($i, j \in \{1, \dots, N\}$). El cálculo de afinidad no lineal mediante el Kernel RBF exige evaluar:

$$K(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|_2^2}{2\sigma^2}\right), \tag{136}$$

donde $\sigma^2 > 0$ representa el ancho de banda (*bandwidth*).

11.2.1. Descomposición Analítica de la Norma Euclídea

Para evitar algoritmos iterativos ineficientes de complejidad $\mathcal{O}(N^2)$ basados en bucles, se expande algebraicamente la norma cuadrática entre pares:

$$\|x_i - x_j\|_2^2 = \langle x_i - x_j, x_i - x_j\rangle = \|x_i\|_2^2 - 2x_i x_j^\top + \|x_j\|_2^2. \tag{137}$$

11.2.2. Construcción Matricial sin Bucles mediante $\mathbf{1}_N$

Para construir la matriz completa de distancias al cuadrado $D^2 \in \mathbb{R}^{N\times N}$, donde $[D^2]_{ij} = \|x_i - x_j\|_2^2$, se vectoriza el procedimiento con el vector de unos $\mathbf{1}_N = [1, 1, \dots, 1]^\top \in \mathbb{R}^{N\times 1}$:

1. **Matriz de productos cruzados:** Se calcula la matriz de Gram lineal:

$$G = XX^\top \in \mathbb{R}^{N\times N}, \quad \text{donde } G_{ij} = x_i x_j^\top. \tag{138}$$

   Los elementos de su diagonal principal corresponden a las normas al cuadrado de cada observación individual: $G_{ii} = x_i x_i^\top = \|x_i\|_2^2$.

2. **Vector columna de normas:** Se extrae la diagonal como vector $z \in \mathbb{R}^{N\times 1}$:

$$z = \operatorname{diag}(XX^\top) = \begin{bmatrix} \|x_1\|_2^2 \\ \|x_2\|_2^2 \\ \vdots \\ \|x_N\|_2^2 \end{bmatrix} \in \mathbb{R}^{N\times 1}. \tag{139}$$

3. **Expansión matricial por producto externo:**

   - Replicación horizontal a lo largo de las columnas mediante $z\mathbf{1}_N^\top \in \mathbb{R}^{N\times N}$:

$$z\mathbf{1}_N^\top = \begin{bmatrix} \|x_1\|_2^2 \\ \|x_2\|_2^2 \\ \vdots \\ \|x_N\|_2^2 \end{bmatrix} \begin{bmatrix} 1 & 1 & \cdots & 1 \end{bmatrix} = \begin{bmatrix} \|x_1\|_2^2 & \|x_1\|_2^2 & \cdots & \|x_1\|_2^2 \\ \|x_2\|_2^2 & \|x_2\|_2^2 & \cdots & \|x_2\|_2^2 \\ \vdots & \vdots & \ddots & \vdots \\ \|x_N\|_2^2 & \|x_N\|_2^2 & \cdots & \|x_N\|_2^2 \end{bmatrix}. \tag{140}$$

   - Replicación vertical a lo largo de las filas mediante $\mathbf{1}_N z^\top \in \mathbb{R}^{N\times N}$:

$$\mathbf{1}_N z^\top = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} \begin{bmatrix} \|x_1\|_2^2 & \|x_2\|_2^2 & \cdots & \|x_N\|_2^2 \end{bmatrix} = \begin{bmatrix} \|x_1\|_2^2 & \|x_2\|_2^2 & \cdots & \|x_N\|_2^2 \\ \|x_1\|_2^2 & \|x_2\|_2^2 & \cdots & \|x_N\|_2^2 \\ \vdots & \vdots & \ddots & \vdots \\ \|x_1\|_2^2 & \|x_2\|_2^2 & \cdots & \|x_N\|_2^2 \end{bmatrix}. \tag{141}$$

4. **Formulación matricial cerrada de D^2:**

$$D^2 = z\mathbf{1}_N^\top - 2XX^\top + \mathbf{1}_N z^\top \in \mathbb{R}^{N\times N}. \tag{142}$$

   Cada entrada de esta matriz satisface exactamente:

$$[D^2]_{ij} = \|x_i\|_2^2 - 2x_i x_j^\top + \|x_j\|_2^2 = \|x_i - x_j\|_2^2. \tag{143}$$

11.2.3. Evaluación del Kernel y Análisis Asintótico de σ^2

La evaluación matricial del Kernel Gaussiano se realiza aplicando el operador exponencial componente a componente:

$$K = \exp\left(-\frac{D^2}{2\sigma^2}\right) \in \mathbb{R}^{N\times N}. \tag{144}$$

Puesto que $[D^2]_{ii} = 0$, se cumple rigurosamente que $K_{ii} = \exp(0) = 1$ en toda la diagonal principal. El comportamiento del sistema según los regímenes asintóticos de σ^2 revela su rol hiperparamétrico fundamental:

- **Régimen $\sigma^2 \to 0$ (Sobreajuste extremo):** Para cualquier par de observaciones distintas $x_i \neq x_j$, el cociente en el exponente diverge:

$$\lim_{\sigma^2\to 0} \frac{\|x_i - x_j\|_2^2}{2\sigma^2} = +\infty \quad \Longrightarrow \quad K_{ij} = \exp(-\infty) = 0 \quad (\forall i \neq j). \tag{145}$$

  La matriz colapsa en la matriz identidad:

$$K \longrightarrow I_N. \tag{146}$$

  Cada muestra queda aislada ortogonalmente de todas las demás; se destruye la noción de vecindad y similitud espacial.

- **Régimen $\sigma^2 \to \infty$ (Subajuste extremo):** Para todo par de puntos:

$$\lim_{\sigma^2\to \infty} \frac{\|x_i - x_j\|_2^2}{2\sigma^2} = 0 \quad \Longrightarrow \quad K_{ij} = \exp(0) = 1 \quad (\forall i, j). \tag{147}$$

  La matriz colapsa en una matriz constante de unos:

$$K \longrightarrow \mathbf{1}_N \mathbf{1}_N^\top. \tag{148}$$

  El espacio pierde toda capacidad de discriminación; todas las muestras se consideran idénticas.

El diseño en aprendizaje de máquina exige seleccionar un valor intermedio de σ^2 que capture las geometrías y relaciones no lineales subyacentes.

11.3. Demostración Algebraico-Matricial de la Covarianza Muestral en $\phi(X)$

Consideremos la matriz de datos $X \in \mathbb{R}^{N\times P}$ como una variable aleatoria matricial y su correspondiente mapeo a un espacio de Hilbert $\phi(X) \in \mathbb{R}^{N\times Q}$ con $Q \to \infty$.

11.3.1. Definición de Momentos y Alineación Dimensional

La esperanza de la transformación define el centro de masa funcional o media poblacional:

$$\mathbb{E}\{\phi(X)\} = \mu_H \in \mathbb{R}^{1\times Q}. \tag{149}$$

Bajo el supuesto de N observaciones independientes e idénticamente distribuidas (i.i.d.), el estimador muestral insesgado de la media funcional es:

$$\mu_H = \frac{1}{N}\sum_{n=1}^{N} \phi(X_n) = \frac{1}{N}\mathbf{1}_N^\top \phi(X) \in \mathbb{R}^{1\times Q}. \tag{150}$$

Para restar el promedio a las N observaciones de forma consistente, se estructura la matriz de medias repetidas mediante el producto externo con el vector de unos:

$$\mathbf{1}_N \mu_H \in \mathbb{R}^{N \times Q}. \tag{151}$$

Puesto que $Q \to \infty$, no es posible calcular una matriz de covarianza de características $\mathbb{R}^{Q \times Q}$. En su lugar, se evalúa la covarianza entre observaciones proyectadas mediante el producto externo de las matrices centradas, asegurando una dimensión finita $N \times N$:

$$\operatorname{cov}(\phi(X), \phi(X)) = \mathbb{E}\left\{(\phi(X) - \mathbf{1}_N \mu_H)(\phi(X) - \mathbf{1}_N \mu_H)^\top\right\} \in \mathbb{R}^{N \times N}. \tag{152}$$

11.3.2. Expansión Paso a Paso y Simplificación de Términos Cruzados

Aplicando la propiedad algebraica de transposición de productos matriciales $(AB)^\top = B^\top A^\top$:

$$(\phi(X) - \mathbf{1}_N \mu_H)^\top = \phi^\top(X) - (\mathbf{1}_N \mu_H)^\top = \phi^\top(X) - \mu_H^\top \mathbf{1}_N^\top. \tag{153}$$

Sustituyendo y expandiendo el producto de binomios:

$$\begin{aligned}(\phi(X) - \mathbf{1}_N \mu_H)(\phi(X) - \mathbf{1}_N \mu_H)^\top &= (\phi(X) - \mathbf{1}_N \mu_H)(\phi^\top(X) - \mu_H^\top \mathbf{1}_N^\top) \\ &= \phi(X)\phi^\top(X) - \phi(X)\mu_H^\top \mathbf{1}_N^\top - \mathbf{1}_N \mu_H \phi^\top(X) + \mathbf{1}_N \mu_H \mu_H^\top \mathbf{1}_N^\top.\end{aligned} \tag{154}$$

Aplicando la linealidad del operador de esperanza matemática $\mathbb{E}\{\cdot\}$:

$$\operatorname{cov}(\phi(X), \phi(X)) = \mathbb{E}\{\phi(X)\phi^\top(X)\} - \mathbb{E}\{\phi(X)\}\mu_H^\top \mathbf{1}_N^\top - \mathbf{1}_N \mu_H \mathbb{E}\{\phi^\top(X)\} + \mathbf{1}_N \mu_H \mu_H^\top \mathbf{1}_N^\top. \tag{155}$$

Reemplazando los operadores de esperanza por sus promedios muestrales i.i.d. ($\mathbb{E}\{\cdot\} \to \frac{1}{N}\sum_{n=1}^N \cdot$):

- Primer término (segundo momento no centrado):

$$\mathbb{E}\{\phi(X)\phi^\top(X)\} \Longrightarrow \frac{1}{N}\sum_{n=1}^N \phi(X_n)\phi^\top(X_n). \tag{156}$$

- Segundo término (cruzado):

$$\mathbb{E}\{\phi(X)\}\mu_H^\top \mathbf{1}_N^\top \Longrightarrow \left(\frac{1}{N}\sum_{n=1}^N \phi(X_n)\right)\left(\frac{1}{N}\sum_{n'=1}^N \phi^\top(X_{n'})\right) = \frac{1}{N^2}\sum_{n=1}^N\sum_{n'=1}^N \phi(X_n)\phi^\top(X_{n'}). \tag{157}$$

- Tercer término (cruzado):

$$\mathbf{1}_N \mu_H \mathbb{E}\{\phi^\top(X)\} \Longrightarrow \left(\frac{1}{N}\sum_{n'=1}^N \phi(X_{n'})\right)\left(\frac{1}{N}\sum_{n=1}^N \phi^\top(X_n)\right) = \frac{1}{N^2}\sum_{n=1}^N\sum_{n'=1}^N \phi(X_n)\phi^\top(X_{n'}). \tag{158}$$

- Cuarto término (cuadrático de la media):

$$\mathbf{1}_N \mu_H \mu_H^\top \mathbf{1}_N^\top \Longrightarrow \left(\frac{1}{N}\sum_{n=1}^N \phi(X_n)\right)\left(\frac{1}{N}\sum_{n'=1}^N \phi^\top(X_{n'})\right) = \frac{1}{N^2}\sum_{n=1}^N\sum_{n'=1}^N \phi(X_n)\phi^\top(X_{n'}). \tag{159}$$

Agrupando los términos algebraicos, los dos términos cruzados negativos y el término cuadrático positivo se reducen:

$$\begin{aligned}\operatorname{cov}(\phi(X),\phi(X)) &= \frac{1}{N}\sum_{n=1}^{N}\phi(X_n)\phi^\top(X_n) - \frac{1}{N^2}\sum_{n=1}^{N}\sum_{n'=1}^{N}\phi(X_n)\phi^\top(X_{n'}) \\ &\quad - \frac{1}{N^2}\sum_{n=1}^{N}\sum_{n'=1}^{N}\phi(X_n)\phi^\top(X_{n'}) + \frac{1}{N^2}\sum_{n=1}^{N}\sum_{n'=1}^{N}\phi(X_n)\phi^\top(X_{n'}) \\ &= \frac{1}{N}\sum_{n=1}^{N}\phi(X_n)\phi^\top(X_n) - \frac{1}{N^2}\sum_{n=1}^{N}\sum_{n'=1}^{N}\phi(X_n)\phi^\top(X_{n'}). \end{aligned} \tag{160}$$

Puesto que la evaluación del producto interno en Hilbert equivale a la función de Kernel $\phi(X_n)\phi^\top(X_{n'}) = K(X_n, X_{n'})$, se concluye la deducción escalar de la covarianza:

$$\boxed{\operatorname{cov}(\phi(X),\phi(X)) = \frac{1}{N}\sum_{n=1}^{N}K(X_n,X_n) - \frac{1}{N^2}\sum_{n=1}^{N}\sum_{n'=1}^{N}K(X_n,X_{n'})} \tag{161}$$

En términos de la matriz de Gram $K \in \mathbb{R}^{N\times N}$, esta expresión representa la diferencia entre la traza promedio y la suma de todas las componentes de la matriz normalizadas por N^2:

$$\operatorname{cov}(\phi(X),\phi(X)) = \frac{1}{N}\operatorname{Tr}(K) - \frac{1}{N^2}\mathbf{1}_N^\top K\mathbf{1}_N = \operatorname{sum}\left(\frac{1}{N}\operatorname{diag}(K) - \frac{1}{N^2}K\right). \tag{162}$$

11.4. Resolución del Reto de la Página 45: Deducción Matricial Pura sin Pasar por la Versión Escalar

En la página 45 de los apuntes manuscritos de clase se formula el siguiente desafío:

> *«En la versión matricial no hay escalar. ¿Cómo llegar a esta versión matricial pero siguiendo la versión matricial sin la versión escalar?»*

La respuesta analítica rigurosa se obtiene prescindiendo de sumatorias e introduciendo el operador de proyección ortogonal conocido como la **Matriz de Centrado**.

11.4.1. Definición y Propiedades de la Matriz de Centrado H

Se define la matriz de centrado $H \in \mathbb{R}^{N\times N}$ como:

$$H = I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top. \tag{163}$$

Esta matriz satisface tres propiedades algebraicas fundamentales:

1. **Simetría ($H^\top = H$):**

$$H^\top = \left(I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top\right)^\top = I_N^\top - \frac{1}{N}(\mathbf{1}_N\mathbf{1}_N^\top)^\top = I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top = H. \tag{164}$$

2. **Idempotencia ($H^2 = H$):** Puesto que $\mathbf{1}_N^\top\mathbf{1}_N = N$:

$$\begin{aligned} H^2 &= \left(I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top\right)\left(I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top\right) \\ &= I_N - \frac{2}{N}\mathbf{1}_N\mathbf{1}_N^\top + \frac{1}{N^2}\mathbf{1}_N(\mathbf{1}_N^\top\mathbf{1}_N)\mathbf{1}_N^\top \\ &= I_N - \frac{2}{N}\mathbf{1}_N\mathbf{1}_N^\top + \frac{N}{N^2}\mathbf{1}_N\mathbf{1}_N^\top \\ &= I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top = H. \end{aligned} \tag{165}$$

3. **Anulación de medias ($H\mathbf{1}_N = \mathbf{0}_N$ y $\mathbf{1}_N^\top H = \mathbf{0}_N^\top$):**

$$H\mathbf{1}_N = \left(I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top\right)\mathbf{1}_N = \mathbf{1}_N - \frac{1}{N}\mathbf{1}_N(N) = \mathbf{0}_N. \tag{166}$$

11.4.2. Centrado Matricial Directo en el Espacio de Hilbert

La matriz de características centradas $\phi_c(X) \in \mathbb{R}^{N\times Q}$ se obtiene restando algebraicamente su media muestral $\mu_H = \frac{1}{N}\mathbf{1}_N^\top\phi(X)$:

$$\begin{aligned}\phi_c(X) &= \phi(X) - \mathbf{1}_N\mu_H \\ &= \phi(X) - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top\phi(X) \\ &= \left(I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top\right)\phi(X) \\ &= H\phi(X).\end{aligned} \tag{167}$$

11.4.3. Deducción de la Matriz de Gram Centrada K_c

Definiendo la covarianza muestral matricial pura a través del producto de las características centradas en el espacio de Hilbert:

$$K_c = \phi_c(X)\phi_c(X)^\top. \tag{168}$$

Sustituyendo $\phi_c(X) = H\phi(X)$ y empleando la propiedad transpuesta $(AB)^\top = B^\top A^\top$ junto con la simetría $H^\top = H$:

$$\begin{aligned}K_c &= (H\phi(X))(H\phi(X))^\top \\ &= H\phi(X)\phi^\top(X)H^\top \\ &= H\left(\phi(X)\phi^\top(X)\right)H \\ &= \boxed{HKH \in \mathbb{R}^{N\times N}}\end{aligned} \tag{169}$$

Esta es la formulación puramente matricial buscada: **la matriz de Gram centrada K_c se obtiene directamente pre y posmultiplicando la matriz de Kernel K por la matriz de centrado H**, sin descomponer en escalares ni manipular sumatorias.

11.4.4. Demostración de Equivalencia con la Expresión de Traza

Al calcular la dispersión escalar total mediante la traza normalizada de K_c, y aprovechando la propiedad cíclica de la traza ($\mathrm{Tr}(ABC) = \mathrm{Tr}(BCA)$) junto con la idempotencia $H^2 = H$:

$$\begin{aligned}\frac{1}{N}\mathrm{Tr}(K_c) &= \frac{1}{N}\mathrm{Tr}(HKH) = \frac{1}{N}\mathrm{Tr}(KH^2) = \frac{1}{N}\mathrm{Tr}(KH) \\ &= \frac{1}{N}\mathrm{Tr}\left(K\left(I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top\right)\right) \\ &= \frac{1}{N}\mathrm{Tr}(K) - \frac{1}{N^2}\mathrm{Tr}(K\mathbf{1}_N\mathbf{1}_N^\top) \\ &= \frac{1}{N}\mathrm{Tr}(K) - \frac{1}{N^2}\mathbf{1}_N^\top K\mathbf{1}_N \\ &= \frac{1}{N}\sum_{n=1}^{N}K(X_n, X_n) - \frac{1}{N^2}\sum_{n=1}^{N}\sum_{n'=1}^{N}K(X_n, X_{n'}).\end{aligned} \tag{170}$$

Queda demostrado que la formulación matricial pura $K_c = HKH$ contiene de manera intrínseca e idéntica la suma de covarianzas escalares.

11.4.5. El Operador de Covarianza en Espacios RKHS de Dimensión Infinita

Para dotar de rigor estocástico y funcional al cálculo en espacios de dimensión infinita, se formaliza la diferencia fundamental entre el espacio de entrada y el espacio RKHS $\mathcal{H}_\kappa$:

- **En el espacio euclídeo $\mathbb{R}^P$:** Para variables aleatorias multidimensionales, la covarianza se describe mediante la matriz de dispersión paramétrica:

$$\Sigma_X = \mathbb{E}\left[(X - \mu_X)(X - \mu_X)^\top\right] \in \mathbb{R}^{P\times P}. \tag{171}$$

- **En el espacio de Hilbert $\mathcal{H}_\kappa$:** Puesto que $Q \to \infty$, no existe una matriz de covarianza de dimensión finita. En su lugar, el objeto formal es el **Operador de Covarianza Cruzada Centrado** $\mathcal{C}_{XY} : \mathcal{H}_\ell \to \mathcal{H}_\kappa$:

$$\mathcal{C}_{XY} \triangleq \mathbb{E}_{X,Y}\left[(\phi(X) - \mu_\kappa) \otimes (\psi(Y) - \mu_\ell)\right], \tag{172}$$

  donde $\otimes$ denota el producto tensorial en el espacio de Hilbert. Dicho operador cumple la propiedad reproductora fundamental:

$$\langle f, \mathcal{C}_{XY} g\rangle_{\mathcal{H}_\kappa} = \mathrm{Cov}(f(X), g(Y)), \quad \forall f \in \mathcal{H}_\kappa,\ g \in \mathcal{H}_\ell. \tag{173}$$

Criterio de Independencia de Hilbert-Schmidt (HSIC). Para cuantificar la dependencia funcional no lineal sin evaluar operadores de dimensión infinita, se emplea la norma de Hilbert-Schmidt al cuadrado del operador centrado:

$$\mathrm{HSIC}(X, Y) \triangleq \|\mathcal{C}_{XY}\|^2_{\mathrm{HS}}. \tag{174}$$

Bajo una muestra finita de tamaño N, el estimador empírico matricial compacto se computa como:

$$\widehat{\mathrm{HSIC}}(X, Y) = \frac{1}{(N-1)^2}\mathrm{Tr}(KHLH) = \frac{1}{(N-1)^2}\mathrm{Tr}(K_c L_c), \tag{175}$$

donde:

- $K \in \mathbb{R}^{N\times N}$ es la matriz de Gram de X, obtenida de forma vectorizada mediante $D^2 = z\mathbf{1}_N^\top - 2XX^\top + \mathbf{1}_N z^\top$.
- $L \in \mathbb{R}^{N\times N}$ es la matriz de Gram de Y (o etiquetas).
- $K_c = HKH$ y $L_c = HLH$ son las respectivas matrices de Gram centradas.

La matriz de centrado $H = I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top$ constituye el operador algebraico fundamental que permite estimar covarianzas funcionales y dependencias de orden superior en espacios RKHS infinitos reduciéndolas a álgebra matricial $N \times N$.